

Kierunek: **Informatyka Stosowana (IST)**
Specjalność: **Zastosowania Specjalistycznych Technologii
Informatycznych (ZST)**

**PRACA DYPLOMOWA
MAGISTERSKA**

**Badanie wpływu kontekstu zapytań i treści zadań
wprowadzanych do sztucznej inteligencji na generowane
odpowiedzi**

Mariusz Kania

Opiekun pracy
Dr hab. inż. Ryszard Klempous

Słowa kluczowe: kontekst zapytań, generatywne modele językowe, Large Language Models (LLM), NLP, prompt engineering, sztuczna inteligencja, ewaluacja modeli

Streszczenie

Przedstawiona praca magisterska poświęcona jest analizie działania dużych modeli językowych, ze szczególnym uwzględnieniem przetwarzania języka naturalnego (NLP) oraz znaczenia kontekstu i formy zapytań w procesie generowania odpowiedzi. Głównym celem pracy było zbadanie, w jaki sposób formułowanie pytań lub zadań wpływa na jakość i skuteczność odpowiedzi generowanych przez LLM. W części teoretycznej przedstawiono podstawowe zagadnienia związane ze sztuczną inteligencją oraz NLP, omówiono ogólną zasadę działania, scharakteryzowano nowoczesne modele językowe, a także ich praktyczne zastosowania. Szczególną uwagę poświęcono roli kontekstu oraz trudnościom, jakie napotykają duże modele językowe podczas przetwarzania zapytań o zróżnicowanej strukturze i precyzji. W części badawczej opracowano i przeprowadzono analizę porównawczą, w której oceniano jakość odpowiedzi generowanych przez różne narzędzia AI oparte na LLM dla przygotowanego zestawu pytań i zadań. Badanie objęło również ankietę użytkowników, których opinie posłużyły do oceny użyteczności i trafności uzyskanych odpowiedzi. Wyniki badań wskazują na istotną zależność pomiędzy sposobem sformułowania zapytania, a jakością odpowiedzi uzyskiwanych od modeli językowych. W pracy dokonano analizy i interpretacji wyników, omówiono ograniczenia badań oraz zaproponowano kierunki dalszych analiz. Praca łączy aspekty teoretyczne z praktycznymi, oferując wsparcie dla użytkowników narzędzi AI na dużych modelach językowych.

Abstract

The presented master's thesis is devoted to the analysis of the operation of large language models, with particular emphasis on natural language processing (NLP) and the importance of context and form of queries in the process of generating answers. The main goal of the work was to investigate how the formulation of questions or tasks affects the quality and effectiveness of answers generated by LLM. The theoretical part presents the basic issues related to artificial intelligence and NLP, discusses the general principle of operation, characterizes modern language and their practical applications. Particular attention was paid to the role of context and the difficulties encountered by large language models when processing queries of diverse structure and precision. In the research part, a comparative analysis was developed and conducted, in which the quality of answers generated by various AI tools based on LLM for the prepared set of questions and tasks was assessed. The study also included a user survey, whose opinions were used to assess the usefulness and accuracy of the obtained answers. The research results indicate a significant relationship between the way the query is formulated and the quality of answers obtained from language models. The paper analyzes and interprets the results, discusses the limitations of the research, and suggests directions for further analysis. The paper combines theoretical and practical aspects, offering support for users of AI tools on large language models.

Spis treści

1.	Wstęp.....	5
1.1.	Wprowadzenie do tematyki pracy	5
1.2.	Problem badawczy	6
1.3.	Cel pracy	7
1.4.	Zakres badań.....	7
1.5.	Opis struktury pracy	8
2.	Sztuczna inteligencja oraz przetwarzanie języka naturalnego	9
2.1.	Znaczenie sztucznej inteligencji (AI)	9
2.1.1.	Definicja oraz rola sztucznej inteligencji	10
2.1.2.	Ogólna koncepcja budowy oraz zasady działania systemów opartych na AI	12
2.2.	Zagadnienia wprowadzające w obszar przetwarzania języka naturalnego (NLP)	13
2.2.1.	Przetwarzanie języka naturalnego oraz jego znaczenie w obszarze nowych technologii	13
2.2.2.	Ewolucja metod przetwarzania języka naturalnego na przestrzeni czasu	14
2.2.3.	Etapy działania oraz podstawowe architektury współczesnych narzędzi NLP.....	16
2.3.	Charakterystyka modeli generatywnych.....	17
2.4.	Zastosowanie istniejących rozwiązań sztucznej inteligencji i ich rola w codziennym życiu.	26
3.	Rola kontekstu zawartego w pytaniach i zadaniach w generowaniu odpowiedzi przez modele AI	27
3.1.	Definicja kontekstu oraz jego rodzaje w przetwarzaniu języka naturalnego	27
3.2.	Znaczenie treści i precyzji zapytań na generowane odpowiedzi przez modele AI	28
3.3.	Trudności w zrozumieniu zapytań i zadań przez modele językowe.....	29
4.	Metodologia badawcza.....	30
4.1.	Charakterystyka badań.....	30
4.2.	Procedura badawcza	30
4.3.	Opis i konstrukcja ankiety badawczej	31
4.4.	Dobór i opis uczestników badania.....	32
4.5.	Modele AI wykorzystane w analizie porównawczej	33
4.6.	Zestaw pytań oraz zadań użytych w badaniu	34
4.7.	Metody analizy danych uzyskanych w trakcie badań.....	34

5.	Wyniki przeprowadzonych badań	35
5.1.	Wyniki ankiety dotyczącej oceny jakości odpowiedzi wygenerowanych przez różne narzędzia AI	35
5.2.	Wyniki analizy porównawczej odpowiedzi generowanych przez różne modele AI	47
5.3.	Zestawienie i prezentacja wyników szczegółowych	54
6.	Analiza wyników badań	59
6.1.	Szczegółowa analiza wyników badań ankietowych	59
6.2.	Szczegółowa analiza porównawcza odpowiedzi uzyskanych od modeli AI	60
6.3.	Czynniki mające największy wpływ na różnice między odpowiedziami	62
7.	Interpretacja wyników badań	63
7.1.	Ocena zgodności wyników badań z przyjętymi hipotezami.....	63
7.2.	Omówienie ograniczeń przeprowadzonych badań	64
7.3.	Rekomendacje praktyczne oraz możliwości dalszych badań	65
8.	Podsumowanie	67
8.1.	Podsumowanie zrealizowanych badań	67
8.2.	Wnioski końcowe z przeprowadzonych analiz.....	68
	Bibliografia	69
	Spis wykresów	73
	Spis rysunków	74
	Spis załączników	74

1. Wstęp

W poniższym rozdziale przedstawiono wprowadzenie do tematyki pracy oraz sformułowano główny problem badawczy. Określono także cel, zakres badań i zaprezentowano strukturę całego opracowania.

1.1. Wprowadzenie do tematyki pracy

W ciągu ostatnich 65 lat, badania nad sztuczną inteligencją (AI) stały się ważnym obszarem zainteresowania zarówno naukowców, jak i inżynierów na całym świecie [1]. Pierwotnym impulsem do rozwoju dziedziny sztucznej inteligencji było dążenie człowieka do stworzenia maszyny osiągającej poziom intelektualny zbliżony do ludzkiego w celu zwiększenia produktywności oraz ludzkiej ciekawości. Obecnie, mimo różnorodnych prób definiowania sztucznej inteligencji, panuje zgoda, co do tego, że jej nadrzędnym celem jest budowanie narzędzi zdolnych do interpretacji danych, uczenia się na ich podstawie oraz adaptacji swojego zachowania w celu wykonywania zadań naśladując funkcje ludzkiego umysłu [2].

W wielu sferach życia społeczno-gospodarczego zaczęto wdrażać AI, rozpoczynając od przemysłu, transportu, przez medycynę i edukację, kończąc na usługach finansowych. Nowoczesne systemy wykorzystują AI jako narzędzie służące do rozpoznawania obrazów, rekomendacji, a także są wykorzystywane w pojazdach autonomicznych oraz we wsparciu przez inteligentnych asystentów głosowych. Wspomniane wcześniej narzędzia stają się nie tylko wyimaginowanym wyobrażeniem przyszłości, lecz codziennością [1].

Rozwój technologii w ciągu ostatnich dwóch dekad, szczególnie w dziedzinie uczenia głębokiego oraz dużych modeli językowych, takich jak GPT, umożliwił ich praktyczne wykorzystanie w wielu obszarach życia. [1] Generatywna sztuczna inteligencja, będąca szczególnym rodzajem technologii AI oraz uczenia głębokiego, skupia się m.in. na automatycznym tworzeniu różnorodnych treści, istotnie zmieniając sposób interakcji człowieka z komputerami. Jej celem nie jest przewidywanie, lecz naśladowanie człowieka w komunikacji oraz kreowaniu treści. Dzięki temu maszyny potrafią uczyć się i reagować na bodźce językowe bez konieczności precyzyjnego programowania przez użytkownika. W szczególności ChatGPT przyczynił się do przełomowych osiągnięć w zakresie przetwarzania języka naturalnego [3]. Z tego powodu wartość rynku sztucznej inteligencji ciągle rośnie, co potwierdza jej znaczenie i dalszy potencjał rozwoju technologii [1].

Jednak sztuczna inteligencja nie zawsze była tak bardzo popularna, ponieważ wielokrotnie obserwowano spadki zainteresowania i liczby prowadzonych badań w tym zakresie [1]. Także istotnym czynnikiem był brak zaufania ze strony inwestorów spowodowany ograniczeniami dostępności mocy obliczeniowej oraz dużych zbiorów danych. Dopiero rozwój tych zasobów umożliwił dalsze badania w obszarze sztucznej inteligencji, a w szczególności sieci neuronowych będących fundamentem większości narzędzi AI [2].

Pomimo znaczących osiągnięć AI, a dokładnie dużych modeli językowych, nadal istnieją istotne wyzwania związane z ich działaniem. Jednym z najczęściej wskazywanych problemów są tzw. halucynacje generowane przez modele językowe. Halucynacje występujące w odpowiedziach polegają na generowaniu treści niezgodnych z wprowadzonym kontekstem lub nieprawdziwych faktów [4]. Zjawisko to jest efektem ubocznym sposobu działania modeli językowych, które bazują na statystycznym przewidywaniu kolejnych słów, a nie na rzeczywistym rozumieniu treści. Wprowadzanie odpowiedniego kontekstu w zapytaniach może ograniczać występowanie halucynacji, jednak całkowite ich wyeliminowanie, wciąż pozostaje nierozwiązanym problemem.

Problem halucynacji jest kluczowy w sektorach o dużej wrażliwości na błędy, takich jak medycyna, czy finanse, gdzie błędne informacje mogą powodować poważne konsekwencje. Z tego powodu analiza sposobu, w jaki kontekst oraz dane wejściowe wpływają na zachowanie modeli jest szczególnie istotnym zagadnieniem w kontekście badań na temat sztucznej inteligencji [4].

1.2. Problem badawczy

Ciągły rozwój technologii w zakresie sztucznej inteligencji przyczynił się do zastosowania AI w wielu sferach życia m.in. obsługi klienta, edukacji, a także systemów rekomendacji. W ostatnich latach szczególną rolę zaczęły odgrywać duże modele językowe, które stanowią istotny element generatywnej sztucznej inteligencji. Ich zastosowanie umożliwiło użytkownikom tworzenie złożonych wypowiedzi, prowadzenie interakcji w języku naturalnym oraz generowanie treści o wysokim poziomie spójności i adekwatności. Jednak ich skuteczność w dużej mierze zależy od tego, w jaki sposób użytkownik formułuje pytanie lub zadanie. Kluczowe znaczenie ma nie tylko precyzyjne sformułowanie polecenia, ale także dostarczenie dodatkowych informacji oraz załączników, które mogą stanowić istotne materiały pomocnicze do realizacji zadania. Modele LLM najlepiej sprawdzają się w zadaniach wymagających przetwarzania języka naturalnego, takich jak generowanie tekstów streszczenia czy prowadzenia konwersacji, wykorzystując przy tym ogromne zasoby wiedzy, które znacznie przekraczają możliwości człowieka.

Istotnym problemem badawczym jest zrozumienie, w jaki sposób różne aspekty zapytań, takie jak kontekst, precyzja, jednoznaczność oraz szczegółowość wpływają na jakość, adekwatność i użyteczność generowanych odpowiedzi. Niepoprawnie określony kontekst lub niedoprecyzowana treść zadania może skutkować generowaniem odpowiedzi błędnych lub zniekształconych, co w pewien sposób ogranicza potencjał wykorzystania dużych modeli językowych w niektórych obszarach działalności.

Jednym z kluczowych wyzwań w pracy z dużymi modelami językowymi jest nie wystarczająca wiedza na temat prawidłowego formułowania zapytań oraz konstruowania treści zadań. Osoby korzystające z LLM oczekują bardziej sprecyzowanych oraz adekwatnych wyników, co czyni tę kwestię niezwykle aktualną.

Problem badawczy obejmuje analizę, jak różne sposoby definiowania kontekstu i treści zadania wpływają na wynik działania poszczególnych modeli AI poprzez porównanie wskaźników jakości generowanych odpowiedzi oraz weryfikację poprawności generowanych treści z wykorzystaniem rzetelnych źródeł. Przeprowadzona analiza ma na celu zoptymalizowanie tworzonych przez użytkowników zapytań, aby generowane odpowiedzi były bardziej trafne, spójne i użyteczne.

Kolejnym istotnym aspektem badań jest percepcja użytkowników w stosunku do generowanych odpowiedzi m.in. ich oczekiwania, subiektywne odczucia oraz zaufanie do technologii. Składowe te wpływają na ocenę jakości i możliwości wykorzystania wygenerowanych treści. W rezultacie analiza uwzględnia zarówno techniczne cechy generowanych wyników, ale także ich interpretację oraz akceptację przez osoby korzystające z różnorodnych narzędzi AI.

Pytania badawcze zrodziły się z zamiaru zbadania, na ile czynniki związane z formułowaniem pytań i poziomem wiedzy użytkowników decydują o uzyskanych odpowiedziach w dostępnych na rynku narzędziach wykorzystujących AI.

Pierwsze z nich dotyczyło kwestii, czy jest możliwość wyraźnego wyodrębnienia grupy użytkowników pod względem stylu i tematyki zapytań – czy pewne charakterystyki wskazują na spójne klastry w danych. Następne pytanie skupiało się na zależności formułowanego kontekstu zapytań, a formą odpowiedzi: czy użytkownicy z określonym celem zastosowania częściej uzyskują obszerne, bardziej analityczne lub złożone odpowiedzi w porównaniu do osób, które szukają wyłącznie błyskawicznej informacji w celu podpowiedzi rozwiązania danego problemu. Istotne było też zbadanie kwestii „hubów” w sieci podobieństwa użytkowników - czy występują węzły, które wyróżniają się wysokim stopniem centralności, a więc łączą w swoich zapytaniach cechy wielu różnych profili.

Kolejne pytania badawcze, dotyczą oceny jakości odpowiedzi generowanych przez modele językowe. Pierwsze weryfikuje, czy sposób formułowania pytań oraz uwzględnianie kontekstu mają duży wpływ na jakość odpowiedzi, ocenianą przy użyciu odpowiednich metryk porównawczych oraz przez zestawienie z wiarygodnymi źródłami informacji. Również istotnym zagadnieniem poruszonym w eksperymencie jest pytanie, czy pytania oraz treści zadań bardziej szczegółowe z określonym kontekstem skutkują uzyskaniem wyższych wyników jakości, czy też precyzja i trafność odpowiedzi pozostają podobne bez względu na sposób formułowania treści wprowadzanych do narzędzi AI.

1.3. Cel pracy

Celem pracy jest omówienie zagadnień w obszarze sztucznej inteligencji, w tym przetwarzania języka naturalnego oraz przeprowadzenie szczegółowej analizy, w jaki sposób kontekst pytań, jak i treści zadań wprowadzanych do sztucznej inteligencji wpływa na jakość, adekwatność i użyteczność generowanych odpowiedzi ze szczególnym uwzględnieniem dużych modeli językowych (LLM).

Dodatkowym założeniem pracy jest przeprowadzenie subiektywnej i obiektywnej oceny jakości generowanych odpowiedzi. W przypadku oceny obiektywnej celem jest wykorzystanie odpowiednich metryk jakości oraz porównanie wyników z rzetelnymi źródłami wiedzy.

Natomiast ocena subiektywna obejmowała przeprowadzenie badań ankietowych, których celem jest zebranie danych zawierających preferencje użytkowników oraz ich ocenę odpowiedzi generowanych przez modele AI. Pozyskane dane posłużą do szczegółowej analizy m.in. profilowania oraz klasteryzacji w celu uzyskania zróżnicowanych grup użytkowników pod względem stylu, sposobu formułowania pytań oraz oczekiwań wobec systemów sztucznej inteligencji.

Ponadto praca zakłada opracowanie zbioru zaleceń dotyczących poprawnego formułowania zapytań kierowanych do modeli językowych, które pozwolą zwiększyć trafność, efektywność oraz użyteczność generowanych odpowiedzi.

1.4. Zakres badań

Zakres badań obejmował analizę użytkowników oraz stosowanych przez nich modeli językowych. Pierwszy etap badań zakładał zebranie szczegółowych danych na temat użytkowników, uwzględniając poziom zawansowania korzystania z modeli językowych, preferowaną formę wypowiedzi lub częstotliwość zadawania pytań. Uzyskane dane zwizualizowano oraz przetworzono na formę numeryczną, w celu dalszej analizy z wykorzystaniem metod ilościowych.

W dalszej części badań zastosowano algorytm klasteryzacji z doбором optymalnej liczby klastrów za pomocą metody łokcia oraz oceniając jakość uzyskanych grup użytkowników wskaźnikami takimi jak Silhouette Score [5], Calinski–Harabasz [6] oraz Davies–Bouldin [7]. Kolejnym etapem było zrozumienie zależności między badanymi cechami, wykorzystując korelację cech i jej wizualizację w postaci mapy cieplnej (ang. heatmapy), a także utworzenie macierzy podobieństwa przy użyciu różnych metryk odległości m.in. euklidesowej, cosinusowej oraz Manhattan. Następnie sprawdzono wariancję wewnątrz klas i zwizualizowano dane za pomocą metody PCA, a także zbudowano graf podobieństwa użytkowników w celu identyfikacji „hubów” w strukturze utworzonej sieci.

W obszarze badań również znalazło się szczegółowe porównanie wybranych modeli językowych m.in. modele OpenAI (GPT 4.5, 4o, o4-mini, o4-mini-high, o3), PLLuM, DeepSeek, Qwen, Gemini, Copilot. Z tego powodu opracowano bazę pytań uwzględniającą takie kryteria jak kontekst wypowiedzi, długość pytania lub obecność słów kluczowych. Porównania modeli dokonano przy pomocy metryk tekstowych m.in.: podobieństwa cosinusowego, Jaccarda, ROUGE, BLEU, BERTScore oraz różnic dotyczących długości generowanych treści oraz ich wartości informacyjnych np. ocena poprzez liczbę unikalnych tokenów (najmniejszych jednostek tekstowych, takich jak słowa lub fragmenty słów w zależności od zastosowanej metody tokenizacji).

Na podstawie uzyskanych wyników opracowano zestaw zaleceń dotyczących formułowania wprowadzanych treści do narzędzi AI wykorzystujących modele językowe, a także sposobów poprawy personalizacji i optymalizacji usług sztucznej inteligencji poprzez zrozumienie różnych profili użytkowników.

1.5. Opis struktury pracy

Struktura pracy składa się z ośmiu rozdziałów, z czego pierwszy jest wstępem, zawierającym omówienie problemu badawczego, celu oraz zakresu badań. Główną, analityczną część tworzą rozdziały od drugiego do siódmego. Natomiast ostatni ósmy zawiera podsumowanie badań oraz końcowe wnioski wynikające z przeprowadzonych analiz.

W rozdziale drugim przedstawiono opis teoretyczny w obszarze sztucznej inteligencji. Na podstawie źródeł literaturowych wskazano znaczenie sztucznej inteligencji oraz zagadnienia wprowadzające w obszar przetwarzania języka naturalnego. W podrozdziale poświęconym podstawowym pojęciom zdefiniowano znaczenie oraz rolę, a w kolejnym omówiono budowę poszczególnych rozwiązań. W dalszych podrozdziałach scharakteryzowano modele oraz wykonano przegląd stanu wiedzy i dostępnych narzędzi.

W przypadku rozdziału trzeciego poruszono tematykę kontekstu i jego wpływu na generowane odpowiedzi. Na początku zdefiniowano kontekst, omówiono jego rodzaje oraz wyjaśniano znaczenie treści i precyzji zapytań na interpretację przez modele językowe. W dalszej części przeanalizowano przykładowe odpowiedzi wygenerowane przez AI, pokazujące bezpośredni wpływ różnych form kontekstu. Dodatkowo poruszono tematykę trudności i wyzwań, jakie modele sztucznej inteligencji napotykają podczas próby interpretacji złożonych zapytań, wskazujących na ograniczenia aktualnych metod przetwarzania języka naturalnego.

Rozdział czwarty poświęcono prezentacji metodologii badawczej. W poszczególnych podrozdziałach poruszone zostały takie aspekty, jak opis charakterystyki badań, ich cel oraz procedura realizacji. Zaprezentowano konstrukcję i zawartość ankiety badawczej, kryteria

doboru uczestników oraz charakterystykę badanej grupy. Omówiono także modele AI wykorzystane w analizie porównawczej, przygotowany zestaw pytań i zadań, jak również metody analizy uzyskanych wyników.

W piątym rozdziale przedstawiono uzyskane wyniki podczas badań m.in. oceny użytkowników dotyczące jakości odpowiedzi wygenerowanych przez narzędzia AI, a także wyniki porównania poszczególnych modeli. Ponadto zebrano i zaprezentowano szczegółowe wyniki odnośnie klasyfikacji użytkowników oraz modeli, dane prezentowane są w postaci tabeli i wykresów.

W rozdziale szóstym dokonano analizy uzyskanych wyników. Dokładnie przeanalizowano rezultaty badań z wykorzystaniem ankiet, przeprowadzono szczegółową analizę porównawczą wygenerowanych odpowiedzi oraz wskazano czynniki, które miały największy wpływ na różnice pomiędzy uzyskanymi odpowiedziami.

Rozdział siódmy stanowi interpretację wyników przeprowadzonych badań, oceniając poprawność uzyskanych rezultatów z przyjętymi hipotezami badawczymi. Dodatkowo omówiono ograniczenia przeprowadzonych badań, a także sformułowano zalecenia, co do wprowadzanych zapytań do narzędzi sztucznej inteligencji.

2. Sztuczna inteligencja oraz przetwarzanie języka naturalnego

W niniejszym rozdziale omówione zostaną najważniejsze zagadnienia dotyczące sztucznej inteligencji (AI) oraz przetwarzania języka naturalnego (NLP). Mają one fundamentalne znaczenie dla rozwoju współczesnych technologii. Sztuczna inteligencja, dzięki zdolnościom symulowania procesów ludzkiego myślenia i zachowania, zajmuje obecnie kluczową pozycję zarówno w codziennym życiu, jak i w innowacyjnych rozwiązaniach informatycznych. Szczególną rolę pełni tutaj przetwarzanie języka naturalnego, które pozwala na efektywną i intuicyjną komunikację między człowiekiem, a maszyną, zarówno za pomocą tekstu, jak i głosu. W kolejnych podrozdziałach szczegółowo przedstawione zostaną definicje, historia rozwoju, kluczowe koncepcje oraz praktyczne przykłady zastosowania systemów opartych na AI i NLP.

2.1. Znaczenie sztucznej inteligencji (AI)

Znaczenie sztucznej inteligencji (AI) we współczesnym świecie stale rośnie, co spowodowane jest zdolnością do naśladowania ludzkiej inteligencji w obszarze rozwiązywania problemów, adaptacji do stale zmieniających się czynników zewnętrznych oraz pozyskiwania wiedzy na podstawie uzyskanych danych [8].

Stały rozwój widoczny we współczesnych realiach społecznych, gospodarczych oraz technologicznych znacząco wpływa na każdą dziedzinę życia, wprowadzając zmiany w funkcjonowaniu wielu organizacji. Rozwój technologii sztucznej inteligencji był efektem wzrostu mocy obliczeniowej oraz postępu w zakresie rozwoju algorytmów służących do przetwarzania danych [9].

Systemy oparte na AI pojawiają się w otoczeniu ludzi w sektorach takich jak przemysł, ochrona zdrowia, transport, edukacja, usługi finansowe, a także w obszarach analizy danych, automatyzacji procesów decyzyjnych oraz optymalizacji działania różnych systemów. Sztuczna inteligencja ze względu na swoje szerokie zastosowania i skalę oddziaływania uznawana jest za kolejną przełomową innowację, przyczyniającą się do zwiększenia efektywności istniejących rozwiązań, umożliwiającą realizację innowacyjnych projektów, które wcześniej nie były możliwe do wdrożenia [1].

Ze względu na złożoność oraz wszechstronne zastosowanie technologii sztucznej inteligencji, jej znaczenie wykracza poza kwestie techniczne i obejmuje również aspekty prawne, etyczne oraz społeczne. Z tego powodu konieczne jest stworzenie odpowiednich regulacji, które zapewnią jej bezpieczne wykorzystanie oraz zgodność z obowiązującymi normami społecznymi i prawnymi [9].

W obecnych czasach trudno wyobrazić sobie funkcjonowanie młodych pokoleń bez zastosowania technologii AI, która coraz częściej staje się impulsem do rozwoju gospodarczego i społecznego. Poglobiona analiza jej roli, począwszy od teorii, poprzez ewolucję technologiczną, aż po sposób działania systemów opartych na sztucznej inteligencji, pozwala dostrzec skalę jej wpływu oraz możliwości dalszego wykorzystania w praktyce.

2.1.1. Definicja oraz rola sztucznej inteligencji

Sztuczna inteligencja (ang. artificial intelligence) to termin pojawiający się w nauce od wielu lat, pomimo ciągłego wykorzystywania tego terminu nie doczekał się jednej powszechnej definicji, co wynika z dynamicznego postępu technologicznego w tej dziedzinie [8]. Twórcą określenia „sztuczna inteligencja” był John McCarthy, który wprowadził je w przestrzeń publiczną w 1955 roku. Jednak od tamtej pory jego definicja była niejednokrotnie poddawana reinterpretacjom [9]. Początkowo terminem sztucznej inteligencji określano próbę odwzorowania ludzkiego umysłu za pomocą odpowiednich algorytmów, lecz w obecnych czasach termin AI obejmuje szerszy zakres rozwiązań technologicznych - od prostych systemów rekomendacyjnych po generatywne modele językowe i autonomiczne pojazdy. Zasadniczo cechą wspólną dla wszystkich interpretacji jest określenie, iż sztuczna inteligencja to próba nadania maszynom zdolności typowych dla inteligencji ludzkiej, takich jak: uczenie się, planowanie, percepcja czy przetwarzanie języka naturalnego [8].

Jedną z najbardziej rozpowszechnianych definicji jest ta zaproponowana przez organizację międzynarodową, którą jest Komisja Europejska. Zgodnie z nią sztuczna inteligencja jest interpretowana, jako systemy posiadające zdolności do analizy otoczenia i podejmowania działań mających na celu uzyskanie zaplanowanych rezultatów [10]. Komisja Europejska swoją definicją chciała podkreślić istotę autonomii oraz celu działania, uwzględniając, iż AI może funkcjonować zarówno w świecie wirtualnym, jak i rzeczywistym. Przykładem zastosowania w świecie wirtualnym może być system rozpoznawania mowy, natomiast w przypadku fizycznych narzędzi są to pojazdy autonomiczne [10].

Z perspektywy filozoficznej, Pei Wang zauważa, iż inteligencja zarówno ludzka jak i sztuczna powinna być interpretowana jako umiejętność adaptacyjnego działania w środowiskach, w których dostęp do informacji i zasobów jest ograniczony. Definicja ta uwzględnia ograniczenia poznawcze i operacyjne, którym przeciwstawić się muszą ludzie oraz maszyny, a także wskazuje na zdolność do podejmowania skutecznych decyzji mimo tych ograniczeń [11].

Inny punkt widzenia prezentują Michael Haenlein i Andreas Kaplan, którzy uważają, że sztuczna inteligencja to system umożliwiający analizę informacji pochodzących z otoczenia, naukę na ich podstawie oraz dostosowanie swojego zachowania w celu realizacji założonych zadań [2]. Poprzez definicję zwrócono uwagę na proces adaptacji będący istotnym elementem reakcji na zmiany warunków otoczenia, co sprawia, że sposób działania systemu staje się zbliżony do tego, w jaki sposób człowiek analizuje i interpretuje rzeczywistość.

Interesujące podejście zaproponował również Dimiter Dobrev, który definiuje sztuczną inteligencję jako program zdolny do funkcjonowania w dowolnym środowisku na poziomie nie gorszym niż człowiek – niezależnie od tego, czy dysponuje on uprzednio wbudowaną wiedzą, czy nie. Autor zakłada, że kluczową cechą AI nie jest posiadanie informacji, lecz zdolność do samodzielnego uczenia się w odpowiedzi na bodźce z otoczenia [12].

W kontekście prawnym i społecznym Ewa Płocha wskazuje, iż sztuczną inteligencję należy traktować jako technologię o szerokim spectrum działania, wpływającą na wiele obszarów życia m.in. sądownictwo i administrację, po transport i edukację. Istotnym aspektem poruszonym przez autorkę jest obligatoryjne uregulowanie kwestii etycznych, odnośnie odpowiedzialności algorytmicznej oraz ochrony praw człowieka [9].

Ciekawy pogląd na temat sztucznej inteligencji zaprezentowano w książce „Generatywna sztuczna inteligencja z ChatGPT i modelami OpenAI”, gdzie autorka rozróżnia sztuczną inteligencję (AI), uczenie maszynowe (ML), głębokie uczenie (DL) oraz generatywną sztuczną inteligencję (GenAI). Sztuczna inteligencja to ogólne pojęcie obejmujące systemy zdolne do wykonywania zadań wymagających inteligencji. AI uważane jako pojęcie nadrzędne obejmujące ML, czyli uczenie na podstawie danych treningowych i doskonalenie modelu wraz z upływem czasu. Z kolei głębokie uczenie to poddziedzina uczenia maszynowego wykorzystująca sieci neuronowe, które są szczególnie skutecznym elementem w dziedzinie przetwarzania języka naturalnego oraz wizji komputerowej. Ostatnim elementem z wyróżnionych obszarów jest generatywna sztuczna inteligencja będąca specjalną formą AI, która umożliwia tworzenie nowych treści takich jak tekst, obrazy, muzyka czy wideo. Generatywna sztuczna inteligencja umożliwia wykorzystanie sztucznej inteligencji w kreatywnych i spersonalizowanych zastosowaniach [3].

W literaturze wyróżnia się również kilka poziomów zaawansowania sztucznej inteligencji m.in.:

- Wąska (ANI - Artificial Narrow Intelligence) obejmująca zakres tylko sprecyzowanych, pojedynczych zadań
- Ogólna (AGI - Artificial General Intelligence) jest to forma sztucznej inteligencji, której poziom zdolności poznawczych we wszystkich dziedzinach dorównuje człowiekowi.
- Super inteligentna (ASI - Artificial Super Intelligence) przewyższająca poziom człowieka w aspekcie inteligencji wraz z emocjonalnym podejściem. Ten rodzaj inteligencji na obecną chwilę jest tylko kierunkiem, do którego dąży ta technologia [1] [2].

Rola sztucznej inteligencji wykracza poza obszar tylko narzędzia – jest ona filarem w dobie transformacji technologicznej społeczeństwa. Jej znaczenie dla ludzkości jest porównywane do wynalazków, takich jak silnik parowy lub komputer. Obszar sztucznej inteligencji stanowi kluczowy element w nauce mający wpływ na przemiany gospodarcze i społeczne [1].

Obecnie rozwój sztucznej inteligencji jest napędzany przez wykorzystanie algorytmów głębokiego uczenia oraz analizę dużych zbiorów danych, co przyczyniło się do znacznego rozwoju technologii takich jak generowanie obrazów, mowy, czy języka naturalnego [12]. Tendencja rozwoju sztucznej inteligencji utrzymuje się do dziś, a w jej ramach stale pojawiają się nowe rozwiązania, w tym dostępne modele będące przykładem jednej z licznych specjalizacji w obrębie AI.

Technologia ta nie tylko jest widoczna w sferach użytkowych, ale także w medycynie, edukacji, kulturze i sztuce. Natomiast jej rozwój rodzi szereg wyzwań m.in. ochrona prywatności, odpowiedzialność za decyzje, które algorytm podjął, czy uprzedzenia w danych treningowych, co do niektórych tematów.

Podsumowując, sztuczna inteligencja jest nie tylko narzędziem, lecz także zjawiskiem o dużym znaczeniu społecznym. Jej definicja, choć wieloaspektowa powinna wskazywać zarówno możliwości techniczne, jak i wpływ na społeczeństwo, które może być znaczące na przestrzeni kilku lat, dlatego definicja powinna poruszać zarówno możliwości, jak i odpowiedzialność w związku z korzystaniem z tej technologii.

2.1.2. Ogólna koncepcja budowy oraz zasady działania systemów opartych na AI

Systemy oparte na sztucznej inteligencji są projektowane w taki sposób, by naśladować mechanizmy myślenia i działania charakterystyczne dla ludzkiego umysłu. Ich głównym celem jest samodzielne uczenie się, rozwiązywanie problemów oraz podejmowanie decyzji na podstawie zgromadzonych danych. Wykorzystują one zdolność do rozpoznawania wzorców i analizowania informacji, co pozwala im efektywnie reagować na różne sytuacje.

Sztuczne sieci neuronowe (Artificial Neural Networks, ANN) stanowią podstawę wielu nowoczesnych rozwiązań z zakresu sztucznej inteligencji. Ich konstrukcja inspirowana jest funkcjonowaniem ludzkiego mózgu – sieć składa się z neuronów, które pełnią rolę prostych jednostek przetwarzających informacje. Każdy neuron odbiera sygnały, przypisuje im odpowiednie wagi, a następnie dokonuje ich sumowania. Wynik ten zostaje przekształcony za pomocą funkcji aktywacji, co pozwala modelowi lepiej uchwycić złożone, nieliniowe zależności w danych. Rozbudowane architektury, zawierające wiele warstw i neuronów, są szczególnie skuteczne w zadaniach takich jak analiza obrazów, czy rozpoznawanie mowy [13] [14]. Pod względem strukturalnym, sieci neuronowe opierają się na modelu warstwowym, obejmuje on warstwę wejściową (przyjmującą dane), jedną lub więcej warstw przetwarzających (tzw. warstwy ukryte), a także warstwę wyjściową, która generuje ostateczny wynik. Każdy z tych poziomów odpowiada za inny etap przekształcania informacji – od podstawowej analizy danych po złożone procesy decyzyjne i klasyfikacyjne [13] [14].

Transformery to przykład jednej z najbardziej zaawansowanych architektur modeli głębokiego uczenia. W modelach sztucznej inteligencji, takich jak GPT zastosowano mechanizm uwagi (ang. self-attention), umożliwiający dynamiczne analizowanie powiązań między poszczególnymi składnikami sekwencji wejściowej. Skutkiem tego jest możliwość uchwycenia przez modele zarówno globalnego i lokalnego kontekstu, co skutkuje większą skutecznością w zadaniach typu generowanie tekstu czy streszczanie informacji. Ze względu na swoją elastyczność oraz możliwość skalowania, architektura transformerów szybko zyskała status fundamentu współczesnych rozwiązań opartych na sztucznej inteligencji [15].

Systemy AI bazują na uczeniu maszynowym, czyli sposobie tworzenia na podstawie danych modeli matematycznych. Wyróżnia się kilka typów uczenia m.in. nadzorowane, nienadzorowane oraz przez wzmacnianie. Uczenie nadzorowane polega na nauce modelu na podstawie danych wejściowych i przypisanych im etykiet, w przypadku nienadzorowanego samoistnie wyszukiwane są ukryte struktury w danych. Natomiast uczenie przez wzmacnianie polega na dostosowywaniu swoich działań na podstawie ciągłych interakcji ze środowiskiem, w których pozytywne decyzje są uznawane poprzez system nagród [16] [17].

Jakość działania systemu AI opiera się na jego umiejętności uogólniania, czyli trafnego reagowania na nowe, wcześniej nieznane dane. Istotnym aspektem, aby uzyskać zadowalającą jakość jest odpowiednie zastosowanie metod uczenia modelu m.in. spadek gradientu i propagacja wsteczna błędu, które pozwalają systematycznie korygować wagi sieci, w taki sposób, by zminimalizować różnicę między przewidywanymi, a rzeczywistymi wynikami [14] [18].

W dzisiejszych realiach systemy sztucznej inteligencji są stosunkowo często projektowane jako elastyczne, rozproszone rozwiązania w środowiskach bazujących na chmurach obliczeniowych. Rozwiązanie to umożliwia przetwarzanie ogromnych ilości danych w czasie rzeczywistym, co jest kluczowym aspektem w dziedzinach takich jak: analiza danych strumieniowych, prognozowanie rynków finansowych czy sterowanie pojazdami autonomicznymi. Architektura systemów sztucznej inteligencji powinna być starannie zaprojektowana, aby oprócz zapewnienia wysokiej wydajności obliczeniowej, cechowała się modułową konstrukcją, odpornością na awarie, bezpieczeństwem oraz zdolnością do integracji z innymi systemami i źródłami danych [19].

2.2. Zagadnienia wprowadzające w obszar przetwarzania języka naturalnego (NLP)

Komunikacja pomiędzy człowiekiem, a komputerem za pomocą języka naturalnego stała się istotnym elementem w procesie współczesnego rozwoju AI. Przetwarzanie języka naturalnego (ang. Natural Language Processing, NLP) jest to obszar badań obejmujący integrację wielu dziedzin m.in. lingwistyki, informatyki, statystyki oraz uczenia maszynowego. Badania te dążą do opracowania odpowiednich metod, aby maszyny potrafiły analizować, interpretować i tworzyć komunikaty językowe [20].

Dynamiczny przyrost danych tekstowych oraz mowy sprawia, iż przetwarzanie języka naturalnego zyskuje na znaczeniu jako kluczowa technologia analizy danych. NLP często znajduje zastosowanie w wielu obszarach takich jak: tłumaczenia maszynowe, przetwarzanie mowy, wykrywanie emocji w tekście, streszczanie treści oraz tworzenie inteligentnych asystentów i chatbotów stosowanych w różnych dziedzinach życia. Są one wykorzystywane w sektorze publicznym i prywatnym [1] [2]. Odpowiednie zastosowanie przetwarzania języka naturalnego umożliwia poprawę komunikacji człowiek-komputer, ale także uporządkowanie informacji zawartych w dużych zbiorach.

Przetwarzanie języka naturalnego przeszło istotną przemianę począwszy od systemów opartych na regułach językowych, poprzez metody statystyczne, aż po współczesne podejścia wykorzystujące uczenie głębokie i transformery. Nowoczesne modele GPT, odegrały istotną rolę w przełomie technologicznym, umożliwiając rozumienie kontekstu zapytań oraz generowanie tekstów o wysokim poziomie językowym. Treści generowane przez modele często porównywane są z komunikacją z człowiekiem [15] [18].

W dalszej części rozdziału omówione zostaną podstawowe koncepcje NLP, jego rozwój historyczny oraz techniczne aspekty działania współczesnych systemów przetwarzających język naturalny.

2.2.1. Przetwarzanie języka naturalnego oraz jego znaczenie w obszarze nowych technologii

Przetwarzanie języka naturalnego (ang. Natural Language Processing, NLP) to dziedzina koncentrująca się na opracowaniu metod i narzędzi, które umożliwią komputerom analizę, interpretację oraz generowanie ludzkiej mowy, za pomocą której człowiek

komunikuje się. Celem tej dziedziny jest stworzenie odpowiedniego, jak i łatwego sposobu porozumiewania się na linii komputer-człowiek [20].

Współczesne podejście do przetwarzania języka naturalnego wykracza poza obszar analizy składniowej zdań oraz przypisywania słowom odpowiednich ról gramatycznych. Pojawiającym się często zjawiskiem jest konieczność tworzenia systemów zdolnych do obszernej analizy znaczenia przetwarzanego tekstu. Podejście to określane jako Natural Language Understanding (NLU), bazuje na założeniu, iż systemy komputerowe powinny nie tylko identyfikować struktury językowe, ale również rozumieć ich sens w danym kontekście przy uwzględnieniu intencji wypowiedzi oraz relacji między pojęciami. [21]

Prawidłowe zrozumienie tekstu przez system komputerowy wymaga opracowania takiej formy reprezentacji wiedzy, która będzie niezależna od języka użytego do jej wyrażenia. Rozwiązanie to umożliwia bardziej obszerną oraz elastyczną analizę tekstu będącą istotnym elementem w realiach wielojęzycznego oraz dynamicznie rozwijającego się środowiska [21].

Przetwarzanie języka naturalnego staje się technologią mającą istotne znaczenie strategiczne dla wielu sektorów publicznych. Technologia ta umożliwia sprawne przeszukiwanie tekstowych baz danych, streszczanie artykułów, opracowywanie wyników oraz wiele innych. W obszarze biznesowym NLP umożliwia podejmowanie decyzji, automatyzację wszelkich procesów komunikacyjnych oraz posiadanie obszernej wiedzy, dzięki dostępowi do dużych dokumentów tekstowych [20].

Uczenie maszynowe, które odegrało istotną rolę w rozwoju NLP, przyczyniło się do zwiększenia zapotrzebowania na efektywne techniki pracy z danymi. W jednym z artykułów autorstwa Li, Hou i Che dokonano przeglądu technik przetwarzania danych, w którym pokazano, iż umożliwiają one powiększanie zbiorów danych treningowych, co jest istotne podczas trenowania modeli językowych w warunkach niskiej dostępności danych. Dzięki wykorzystaniu odpowiednich technik możliwy jest dalszy rozwój NLP, jak również języków, dla których brakuje dużych zbiorów danych, oraz wąskich dziedzin tematycznych [22].

Współczesne systemy informatyczne NLP usprawniają nie tylko komunikację, ale także wykorzystywane są jako narzędzie analityczne i poznawcze, które umożliwia przetwarzanie oraz analizę dużych zbiorów danych tekstowych w celu wydobycia kluczowych informacji. Dalszy rozwój przetwarzania języka naturalnego odegra kluczową rolę w integracji języka z innymi technologiami sztucznej inteligencji, takimi jak rozpoznawanie obrazów, wnioskowanie logiczne czy komunikacja człowiek-maszyna w czasie rzeczywistym.

2.2.2. Ewolucja metod przetwarzania języka naturalnego na przestrzeni czasu

Przetwarzanie języka naturalnego od początku swojego rozwoju stanowi jeden z najbardziej dynamicznych obszarów w dziedzinie sztucznej inteligencji oraz lingwistyki. Ewolucja NLP odzwierciedla zmieniające się podejście w badaniach nad sztuczną inteligencją, a także coraz większe możliwości technologiczne na przestrzeni czasu. Rozwój przetwarzania języka naturalnego począwszy od wczesnych badań nad językiem, aż po modele oparte na głębokim uczeniu, przebiegał równolegle z rozwojem technologii komputerowych oraz ze zmianami w postrzeganiu języka jako systemu poznawczego.

Początki tej dziedziny przypadły na lata 50.XX wieku, kiedy zainteresowano się automatyczną translacją tekstu. Metoda wykorzystana w pierwszym eksperymencie bazowała głównie na regułach gramatycznych oraz utworzonych słownikach. Ze względu na zbyt liczne wieloznaczności językowe oraz błędnie przekazywane znaczenie zdań,

kluczowe było rozwijanie odpowiednich metod służących do zaawansowanej analizy językowej [23]. Systemy wprowadzane w latach 50 były ściśle powiązane z wiedzą ekspertów i logiką formalną, jednak w obliczu złożoności języka naturalnego ich ograniczenia szybko się uwidoczniły.

Na przełomie lat 60 i 70 XX wieku zmieniono podejście do przetwarzania języka naturalnego. Okres ten charakteryzowało ogromne znaczenie metod wykorzystujących reguły semantyczne oraz syntaktyczne, dzięki którym opracowano niezbędne systemy do analizy języka naturalnego. Istotnym elementem były rozszerzone sieci przejść (Augmented Transition Networks), które pozwoliły modelować złożone struktury gramatyczne i semantyczne. Duży nacisk na algorytmy bazujące tylko na wiedzy z zakresu lingwistyki nie wystarczył, ponieważ odkryto, że przetwarzanie języka naturalnego wymaga wiedzy o świecie oraz rozumienia kontekstu, co skutkowało początkiem integracji metod NLP z technikami sztucznej inteligencji [24].

Istotny postęp przyniosły lata 80.XX wieku, kiedy to rozpoczęto integrację technik sztucznej inteligencji m.in. szablonów, scenariuszy, a także sieci semantycznych w celu uwzględnienia wiedzy o świecie w interpretacji języka naturalnego. Umożliwiło to bardziej precyzyjną interpretację tekstów oraz dialogów [23].

W latach 90.XX wieku wprowadzono metody statystyczne w NLP, dzięki którym można było wykorzystać uczenie modeli na podstawie danych treningowych. Zjawisko to spowodowane było dostępnością danych tekstowych i wzrostem mocy obliczeniowej. Pojawienie się metod statystycznych umożliwiło przetwarzanie bez potrzeby ręcznego określania reguł językowych [21]. Modele wytrenowane na podstawie danych treningowych były wykorzystywane do takich zadań jak rozpoznawanie mowy. Również istotna w tych czasach była prezentacja znaczenia zdania za pomocą odpowiednich struktur oraz tworzenie systemów, służących do przeprowadzania analizy znaczenia poszczególnych zdań. Poza tym systemy dialogowe były dużym osiągnięciem w rozwoju NLP, które umożliwiło skuteczną interpretację języka naturalnego [23].

Rewolucją ostatniej dekady oraz początku XXI wieku w zakresie NLP było pojawienie się metod opartych na głębokim uczeniu. Metody bazujące na głębokich sieciach neuronowych m.in. rekurencyjnych sieciach neuronowych (RNN), sieciach LSTM, a także transformerach wpłynęły znacząco na rozwój NLP. Architektura Transformer oraz jej rozszerzenia, takie jak GPT przyczyniły się do osiągnięcia bezprecedensowych wyników precyzji w zadaniach takich jak: analiza tekstu, translacja, analiza sentymentu, czy streszczanie tekstów. Wspomniane techniki opierają się na wektorowych reprezentacjach słów i zdań, umożliwiając uchwycenie złożonych zależności semantycznych oraz kontekstowego znaczenia wyrazów [21] [24].

W obecnych metodach przetwarzania języka naturalnego coraz większą rolę odgrywa połączenie metod lingwistycznych z podejściem opartym na uczeniu głębokim. W tej dziedzinie szczególną wartość mają projekty, które integrują informacje semantyczne pochodzące z różnych języków i źródeł wiedzy, umożliwiając nie tylko przetwarzanie, ale także dogłębną interpretację i zrozumienie tekstu [21]. Przykładem omawianych technik może być system przetwarzania języka naturalnego, który łączy analizę struktur gramatycznych z wykorzystaniem wiedzy encyklopedycznej zawartej w bazach danych, umożliwiając tym samym dokładniejszą interpretację zapytań użytkowników.

Reasumując ewolucja metod NLP przebiegała bardzo dynamicznie począwszy od prostych technik tłumaczenia słownikowego poprzez zaawansowane reguły syntaktyczno-semantyczne, aż po uczenie głębokie. Jednak pomimo ciągłego postępu w tej dziedzinie

istnieje wiele wyzwań związanych ze zrozumieniem języka naturalnego, co stanowi istotę dalszych badań. W niedalekiej przyszłości badania umożliwiają stworzenie bardziej zaawansowanych systemów do przetwarzania języka naturalnego poprzez połączenie wielu dziedzin takich jak sieci neuronowe, lingwistyka oraz technologie semantyczne [21] [23] [24].

2.2.3. Etapy działania oraz podstawowe architektury współczesnych narzędzi NLP

Typowa struktura działania narzędzi NLP obejmuje kilka istotnych etapów. Jednym z pierwszych etapów jest wstępne przetwarzanie danych, które obejmuje m.in. tokenizację (podział tekstu na poszczególne jednostki np.: wyrazy lub zdania), normalizację tekstu (ustandaryzowanie tekstu np.: zamiana liter na małe) oraz usuwanie stop-słów (proces usuwania zbędnych, powtarzających się oraz nieposiadających istotnych informacji wyrazów). Kolejnym krokiem jest analiza morfologiczna, która identyfikuje formy fleksyjne wyrazów, a także przypisuje im odpowiednie kategorie gramatyczne. Następnie przeprowadzona zostaje analiza składniowa, mająca na celu identyfikację struktury zdania za pomocą drzew syntaktycznych oraz grafów, służących do znalezienia zależności pomiędzy poszczególnymi elementami tekstu [20].

Późniejszym etapem jest analiza sensu wypowiedzi na poziomie semantycznym oraz pragmatycznym, która ma na celu określenie intencji autora oraz kontekstu [20]. W praktycznych zastosowaniach stosuje się techniki identyfikacji znaczenia, takie jak wektoryzacja słów, a także modele uwzględniające szerszy kontekst językowy m.in. BERT [25].

Współczesna budowa narzędzi NLP opiera się głównie na algorytmach uczenia maszynowego, zwłaszcza głębokich sieciach neuronowych. Z tego powodu ważnym momentem było wprowadzenie architektury transformerów bazującej na mechanizmie uwagi, a także umożliwiającej równoległe przetwarzanie danych tekstowych, co istotnie zwiększyło efektywność przetwarzania języka naturalnego [15].

Przykładowym modelem wykorzystującym architekturę transformerów jest BERT. Model ten przyswaja reprezentacje językowe, wykorzystując duże zbiory tekstów, bez potrzeby ręcznego przypisywania etykiet. Takie podejście umożliwia rozumienie złożonych zależności semantycznych i syntaktycznych. Wspomniane zdolności modelu umożliwiają zastosowanie go w czynnościach takich jak tłumaczenie maszynowe, generowanie treści oraz klasyfikacja dokumentów [25]. W przypadku nowoczesnych generatywnych modeli, takich jak GPT również bazujących na transformerach stosowane jest dostrajanie modelu na podstawie instrukcji użytkowników oraz transfer informacji z dużych modeli bazowych w celu osiągnięcia jak największej skuteczności [3].

W codziennej pracy w obszarze przetwarzania języka naturalnego często wykorzystuje się narzędzia takie jak biblioteka spaCy [26] rozwijana w języku Python, oferująca szybkość i precyzyjną analizę tekstu oraz Hugging Face Transformers [27], zapewniające łatwy dostęp do wcześniej wytrenowanych modeli, takich jak BERT czy GPT. Obecny kierunek rozwoju NLP koncentruje się na doskonaleniu zdolności do głębszego rozumienia kontekstu i intencji autora, co ma na celu generowanie precyzyjnych, trafnych informacji, nawet w sytuacjach, gdy istnieje wiele możliwych interpretacji danego zagadnienia.

2.3. Charakterystyka modeli generatywnych

Modele generatywne są jedną z najbardziej rozwijających się dziedzin sztucznej inteligencji w XXI wieku. Modele te bazują na głębokich sieciach neuronowych, które umożliwiają rozumienie oraz generowanie tekstu w języku naturalnym, ale także generowanie obrazów, mowy, animacji, czy wielu innych rodzajów danych [3]. W tym rozdziale przedstawione zostaną informacje na temat podstawowych mechanizmów działania modeli językowych, zagadnienia w tematyce modeli generatywnych oraz charakterystyka wybranych współczesnych systemów, w tym modeli OpenAI i alternatywnych rozwiązań, takich jak PLLuM [28], DeepSeek [29] [30], Qwen [31], Gemini [32] [33] i Copilot (GPT-4) [34] [35] [36].

W kontekście modeli językowych warto zapoznać się z kilkoma istotnymi pojęciami takimi jak: token, instrukcja (prompt) oraz pewność modelu. Token to podstawowa jednostka w modelach językowych, która stanowi fragment tekstu będący pojedynczym znakiem, słowem lub jego częścią. Kolejnym istotnym parametrem jest instrukcja (prompt) uznawana jako fragment tekstu będący daną wejściową dla modelu, determinującą sposób realizacji zadania. Ostatnim z istotnych pojęć jest pewność modelu będąca poziomem prawdopodobieństwa, który cechuje odpowiedzi udzielane przez dany model językowy. Poziom ten charakteryzuje poprawność oraz trafność wygenerowanych odpowiedzi [3].

Modele językowe takie jak GPT, są opracowywane na podstawie danych tekstowych o różnym stylu, gatunku i tematyce. Dzięki temu procesowi modele uczą się rozpoznawać kontekst oraz przewidywać kolejne elementy tekstu w sekwencji, dlatego ich zastosowanie nie ogranicza się tylko do generowania tekstu [3]. Wykorzystywane są również w takich zadaniach jak tłumaczenie maszynowe, streszczanie dokumentów, odpowiadanie na pytania, klasyfikacja treści, czy wspomaganie wyszukiwania informacji.

Na początku modele przetwarzające dane sekwencyjne i zachowujące kontekst opierały się na sieciach rekurencyjnych (RNN), które umożliwiały przetwarzanie danych w sposób uwzględniający poprzednie elementy sekwencji. Ich działanie opierało się na przekazywaniu stanu z kroku na krok, co pozwalało uchwycić lokalne zależności w danych czasowych lub tekstowych. Jednak ich ograniczeniem był problem z długoterminowym zapamiętywaniem informacji, wynikający z przetwarzania danych w sposób liniowy i niemożności jednoczesnego uwzględniania odległych elementów sekwencji. Dodatkową barierą były utrudnienia w zrównolegleniu wynikające z sekwencyjnej zasady działania oraz budowy sieci RNN, przez co modele nie mogły w pełni wykorzystać potencjału dzisiejszych kart graficznych. Kluczowym wyzwaniem było także zjawisko zaniku gradientu, które wynikało z wielokrotnego mnożenia gradientów w trakcie wstecznej propagacji. To w efekcie uniemożliwiało skuteczny trening modelu. W odpowiedzi na wspomniane ograniczenia opracowano sieci LSTM, które dzięki zastosowaniu specjalnych komórek pamięci lepiej radzą sobie z przechowywaniem i przekazywaniem informacji w dłuższych sekwencjach czasu. Mechanizm bramek umożliwia kontrolowanie przepływu danych, co pozwala skutecznie ograniczyć problem zaniku gradientu podczas uczenia. Niemniej jednak, LSTM nadal nie pozwalają na efektywne zrównoleglenie obliczeń, co negatywnie wpływa na czas trenowania modeli [3].

W celu zniwelowania tych ograniczeń zaproponowano nową architekturę, którą były transformery. Architektura ta wyeliminowała problem ze zrównolegleniem obliczeń, umożliwiając wykonanie tej operacji oraz przechowywanie długoterminowych zależności, co znacząco poprawiło wydajność modeli w zadaniach przetwarzania języka naturalnego. Transformery składają się z dwóch bloków m.in. enkodera i dekodera. Enkoder odpowiada za przetwarzanie danych wejściowych i tworzenie ich reprezentacji. Natomiast dekodery

generuje wynikową sekwencję na podstawie tych reprezentacji, a także wcześniej wygenerowanych tokenów. Mechanizm samouwagi zwiększa zdolność modelu do uchwycenia kontekstu. Z racji tego, że transformery nie przetwarzają danych w ustalonej kolejności, konieczne było zastosowanie kodowania pozycyjnego, które dostarcza informacji o położeniu poszczególnych tokenów w sekwencji wejściowej. Uzupełnieniem architektury są warstwy sprzężenia w przód, które umożliwiają modelowi lepsze uchwycenie złożonych relacji w danych [3].

Każdy model posiada kilka parametrów sterujących procesem generowania odpowiedzi, co pozwala dostosować styl, długość i kreatywność tekstu. Kluczowym parametrem jest temperatura, odpowiadająca za poziom losowości przy wyborze kolejnych tokenów. Niska wartość parametru skutkuje, iż odpowiedzi są bardziej spójne, natomiast wyższa zwiększa kreatywność i różnorodność wyników. Maksymalna odległość ogranicza liczbę tokenów, jaką model może wygenerować w jednej odpowiedzi. Sekwencje kończące to znaki lub frazy, które zatrzymują generowanie, gdy zostaną rozpoznane. W przypadku najwyższego prawdopodobieństwa ogranicza się wybór tokenów do zbioru tokenów o prawdopodobieństwie nieprzekraczającym ustalonej wartości. W celu ograniczenia powtórzeń w modelach stosuje się karę za częstość lub karę za obecność, które zmniejszają prawdopodobieństwo ponownego pojawienia się tych samych tokenów lub odpowiedzi. Dodatkowo możliwe jest ustawienie stałego tekstu, który będzie pojawiał się przed lub po odpowiedzi modelu, np. w celu zachowania określonego stylu komunikacji [3].

Po omówieniu podstawowych mechanizmów działania modeli językowych jak również ich architektury, warto przeanalizować konkretne rozwiązania obecne na rynku. W tej części podrozdziału zostaną zaprezentowane modele generatywne stworzone przez OpenAI oraz inne alternatywne propozycje modeli oferowanych przez konkurencję. Charakterystyka będzie obejmować cechy poszczególnych modeli, różnice funkcjonalne i preferowane zastosowanie, co pozwoli lepiej zrozumieć praktyczny wymiar działania współczesnych systemów sztucznej inteligencji.

Jednymi z najważniejszych osiągnięć w dziedzinie modeli generatywnych są kolejne iteracje modeli GPT, opracowane przez OpenAI. Do najważniejszych z nich należą m.in.:

- GPT-4.5

GPT-4.5 jest największym osiągnięciem w rozwoju dużych modeli językowych stworzonych przez firmę OpenAI. Jego pierwsza prezentacja odbyła się w lutym 2025. Model został stworzony w celu rozwoju podejścia do uczenia bez nadzoru, gdzie skoncentrowano się na zwiększeniu zdolności modeli do rozpoznawania wzorców, wyciągania wniosków i generowania spójnych wypowiedzi na podstawie dużych zbiorów danych tekstowych [37]. Uczenie GPT-4.5 odbyło się na superkomputerach Microsoft Azure, wykorzystując innowacyjne metody dostrajania, takie jak wzmocnione uczenie się z informacją zwrotną od ludzi (RLHF) oraz nowoczesne podejścia do nadzorowanego fine-tuningu (SFT). Również istotną, nową metodą było zastosowanie technik skalowanego dopasowania modeli, które pozwalają trenować większe modele na danych pochodzących z mniejszych modeli [38].

W modelu tym poprawiono naturalność konwersacji oraz rozpoznawania emocji względem modelu GPT-4o oraz GPT-4.1. Testerzy wskazują na nowe umiejętności udzielania wsparcia emocjonalnego, a także pomoc w bardziej kreatywnych zadaniach, takich jak pisanie i projektowanie [38]. Głównym celem modelu było uzyskanie

wszechstronnej i trafnej interpretacji, co skutkowałoby zmniejszeniem liczby wystąpień halucynacji w odpowiedziach generowanych przez modele [37].

Model GPT-4.5 uzyskał wyższe wyniki w zadaniach weryfikujących wiedzę deklaracyjną. W teście SimpleQA, będącym miarą sprawdzającą w jakim stopniu model radzi sobie z prostymi pytaniami, gdzie w przypadku GPT-4.5 osiągnięto poziom 62,5%, co znacznie przewyższa wynik GPT-4o (38,2%) oraz starszych modeli m.in. o1 na poziomie 47%, a także o3-mini o wartości 15% [37]. Jednocześnie model GPT-4.5 wykazuje najniższy poziom halucynacji spośród porównywanych tylko na poziomie 37%, podczas gdy GPT-4o osiąga 61,8%, a o3-mini aż 80,3% [37]. Taki poziom zwiększa zaufanie oraz wiarygodność, co do odpowiedzi generowanych przez model. Równie istotnym faktem jest, iż GPT-4.5 wypada lepiej nie tylko w testach syntetycznych, ale też w ocenach testerów, zdobywając wyższe noty w zapytaniach codziennych (57%), profesjonalnych (63,2%) i kreatywnych (56,8%), co potwierdza, że ten model lepiej rozumie intencje użytkownika, ułatwiając komunikację i współpracę [37].

W testach akademickich i branżowych model osiągnął m.in. 71,4% w zakresie nauk ścisłych, 36,7% w matematyce 2024 oraz świetne wyniki w zadaniach wielojęzycznych na poziomie 85,1%, a także w testach multimodalnych zdobył 74,4%. Dodatkowo, wykazuje solidne umiejętności w programowaniu, osiągając 32,6% w SWE-Lancer i 38% w SWE-Bench [37].

Zamiast klasycznej techniki „chain-of-thought”, która rozwiązuje problem poprzez rozpisywanie kolejnych kroków rozumowania zastosowano rozwiązanie opierające się na szerokim przetwarzaniu danych i intuicji językowej. Model ten jest przeznaczony głównie do zadań kreatywnych, edukacyjnych i komunikacyjnych. Obsługuje dane tekstowe, graficzne oraz pliki, nie posiada wsparcia dla głosu i wideo [37].

- GPT-4o

Model GPT-4o wprowadzony przez firmę OpenAI w 2024, który zapoczątkował nową generację sztucznej inteligencji poprzez obsługę różnych typów danych m.in.: tekstu, dźwięku, obrazu i wideo. W przeciwieństwie do swoich poprzedników model ten przetwarzał modalności za pomocą jednej wspólnej sieci neuronowej, co umożliwiała płynną interakcję pomiędzy użytkownikiem, a modelem w komunikacji głosowej, gdzie czas reakcji wynosi 320 milisekund, co znacząco jest zbliżone do ludzkiej rozmowy [39].

Porównywalną jakość generowania tekstu i kodu względem GPT-4 Turbo osiąga model GPT-4o, który działa szybciej i przy niższych kosztach, oferując szybszy czas reakcji. GPT-4 Turbo to zoptymalizowana wersja poprzedniego modelu GPT-4, stworzona z myślą o większej wydajności i efektywności, dlatego stanowi istotny punkt odniesienia w porównaniu z jego następcą, czyli GPT-4o. Ponadto zaawansowane trenowanie modelu 4o wykazuje lepsze wyniki w przetwarzaniu języków innych niż angielski, w tym języków mniej popularnych takich jak amharski czy suahili [39].

Proces uczenia bazował na danych z różnorodnych źródeł m.in. otwartych zasobach internetowych, specjalistycznych zbiorach danych, a także materiałach objętych licencją, pozyskanych we współpracy z partnerami. Umożliwiło to przetwarzanie nie tylko tekstu, ale również obrazu, dźwięku i wideo [39].

Istotnym aspektem GPT-4o jest bezpieczeństwo i kwestie etyczne, które zostały zweryfikowane poprzez kompleksowe testy ryzyka przeprowadzone z udziałem 100 ekspertów z 29 różnych krajów, które umożliwiły wykrycie potencjalnych zagrożeń takich jak generowanie treści zabronionych, klonowania głosu i rozpowszechniania dezinformacji. Do tego celu zostały wprowadzone moderacje oraz klasyfikatory treści, a także system odmowy odpowiedzi w przypadku naruszenia zasad [39].

GPT-4o znajduje szerokie zastosowanie w dziedzinach takich jak edukacja, medycyna, analizy finansowe oraz wiele innych. W testach z zakresu wiedzy klinicznej osiągnął wyniki przewyższające wcześniejsze modele, co świadczy o jego przydatności w zadaniach wymagających wysokiej precyzji [39].

- o4-mini

Model o4-mini jest kompaktową wersją czwartej generacji modeli OpenAI, charakteryzujący się szybkością oraz niskimi kosztami przy zachowaniu skuteczności. Wielkością model jest mniejszy w porównaniu do modelu o3, lecz osiąga on również zadowalające wyniki w testach z matematyki, kodowania czy zadaniach multimodalnych, gdzie jego efektywność jest większa niż w innych modelach względem kosztu [40].

W testach matematycznych, takich jak AIME, model o4-mini uzyskał najlepsze rezultaty w porównaniu modeli, osiągając 93,4% poprawnych odpowiedzi w edycji z 2024 roku oraz 92,7% w wersji z 2025 roku. Poprzez wykorzystanie dodatkowych narzędzi takich jak interpreter Pythona wyniki wzrosły do poziomu niemal 100% [40].

W zakresie programowania model o4-mini wypada lepiej niż o3 i o1, ponieważ w konkursie Codeforces uzyskał według punktacji ELO wskaźnik 2719. Jego wynik jest potwierdzeniem, iż stosunkowo dobrze radzi sobie z pisanem oraz poprawianiem kodu. Również w testach praktycznych takich jak SWE-Bench wypada zadowalająco, co potwierdza, iż ten model może być wykorzystywany do codziennej, praktycznej pracy z kodem [40].

Model jest również skuteczny w analizie obrazów, ponieważ posiada umiejętność analizy wykresów, zdjęć lub notatek, nawet w przypadku, gdy są nieczytelne. W testach MathVista czy MMMU, które zawierają zadania wymagające przetworzenia tekstu i grafiki model osiągnął ponad 80% trafności [40].

Warto zaznaczyć, iż o4-mini ma większe limity użytkowania w porównaniu do wcześniejszych wersji m.in. o3-mini, GPT-4 Turbo i GPT-4, co świetnie sprawdza się w zadaniach wymagających dużych zasobów obliczeniowych. Model ten również uzyskał dobre recenzje, w których wskazano na jego użyteczność i trafność, co do przekazywanych poleceń. Dzięki swojej konstrukcji dostosowuje się do użytkownika, wykorzystując swoją pamięć oraz kontekst wcześniejszych rozmów [40].

- o3

Model o3 opublikowany w 2025 roku to jeden z bardziej zaawansowanych systemów, posiadający umiejętność „myślenia” przez udzieleniem odpowiedzi, dzięki czemu jest w stanie przeprowadzać dogłębną analizę danych i samodzielnie decydować w jaki sposób wykorzystywać odpowiednie narzędzia takie jak wyszukiwanie w Internecie, tworzenie wykresów czy pisanie kodu w Pythonie [40].

W testach Codeforces model uzyskał wynik na poziomie 2706 ELO, co było porównywalne z wynikami najlepszych zawodników, natomiast w przypadku SWE-Bench jego skuteczność wyniosła 69,1%. W teście MMMU sprawdzającym wiedzę z różnych dziedzin wypadł satysfakcjonująco, ponieważ jego wynik to 82,9% dokładności, co czyni go liderem w tym obszarze. Model o3 na pytania sprawdzające wiedzę na poziomie osoby z tytułem magistra lub doktora w testach GPQA osiągnął 83,3% trafności, co przewyższa wyniki pozostałych modeli z rodziny OpenAI. Również w zadaniach typu „Humanity's Last Exam” uzyskał wynik 24,90%, co wskazuje na użyteczność modelu do pracy ze specjalistycznymi pytaniami z różnych obszarów nauki [40].

Istotnym elementem modelu o3 jest sposób podejmowania decyzji na temat wykorzystania odpowiedniego narzędzia, co jest szczególnie skuteczne w zadaniach wymagających dostępu do najnowszych danych lub złożonej analizy. Zastosowanie uczenia przez wzmacnianie, spowodowało poprawę skuteczności modelu, która jest proporcjonalna do czasu generowania odpowiedzi. Model o3 popełnia mniej błędów w stosunku do modelu o1, zwłaszcza w generowanych odpowiedziach z zakresu nauk ścisłych i technicznych [40].

Modele OpenAI, takie jak GPT-4.5, 4o oraz pozostałe jego warianty odgrywają istotną rolę w procesie rozwoju sztucznej inteligencji oraz przetwarzania języka naturalnego, oferując zaawansowaną analizę treści, kodu lub obrazu.

Jednak coraz częściej pojawiają się rozwiązania konkurencyjnych firm na rynku, które stają się silną alternatywą oraz wprowadzają nowe możliwości. Do nich należą m.in.:

- DeepSeek

Model Deep Seek jest to model językowy, który został opracowany przez chińską firmę DeepSeek AI. Jest on publicznie udostępniony w ramach licencji open source, obejmującej zarówno kod źródłowy, jak i wagi modelu. Stanowi on przykład architektury typu Mixture-of-Experts (MoE), która umożliwia dynamiczne uruchamianie poszczególnych elementów modelu w trakcie przetwarzania danych, co zwiększa efektywność obliczeń [30].

W przypadku najnowszej wersji DeepSeek-V3, model ten posiada 671 miliardów parametrów. Jednak dzięki technologii MoE wykorzystywane jest jedynie 37 miliardów na token. Takie zużycie pozwala zachować wydajność porównywalną do GPT-4 przy znacznie mniejszym zapotrzebowaniu na zasoby, co przełożyło się na koszt treningu rzędu 5,6 miliona dolarów amerykańskich. W treningu modelu wykorzystano rozwiązania takie jak Multi-head Latent Attention, pozwalające na wychwytywanie ukrytych zależności w danych, strategię równoważenia obciążenia bez dodatkowej funkcji straty. Wykorzystano również technikę przewidywania wielu tokenów jednocześnie, która zwiększa gęstość sygnału uczącego i wspiera planowanie generowanych odpowiedzi. Model został wytrenowany na 14,8 biliona tokenów, których zakres obejmował dane o wysokiej jakości z wielu dziedzin [30].

Model DeepSeek-V3 osiągnął wynik 75,9% w teście MMLU-Pro, który ocenia wiedzę z różnych dziedzin akademickich, w ramach testów porównawczych. W bardziej zaawansowanym teście GPQA-Diamond sprawdzającym wiedzę ekspercką osiągnięto 59,1%. W zadaniach matematycznych model zdobył 90,2%, a w przypadku testu AIME 39,2%. W teście Codeforces skuteczność modelu w programowaniu oceniono na 51,6%, a w SWE-Bench skutecznie rozwiązał tylko 42% [30].

Z kolei model DeepSeek-R1 jest to rozszerzenie modelu V3, który został rozbudowany o pogłębione rozumowanie i logikę. Model został wytrenowany poprzez wykorzystanie uczenia przez wzmacnianie, które bazuje na podejściu pozbawionym nadzorowanego

uczenia, a następnie wzmacniane jest poprzez kolejne fazy. Metodologia ta sprawia, iż model dobrze wypada w zadaniach wieloetapowych, ze względu na specjalnie zaprojektowany system nagród [29].

DeepSeek-R1 uzyskał porównywalne wyniki z najnowszymi modelami 84,0% w MMLU-Pro, 71,5% w GPQA-Diamond, 79,8% w AIME i aż 97,3% w MATH-500, co potwierdza jego skuteczność w zadaniach matematycznych. W przypadku testów z kodowania uzyskał 2029 punktów ELO w Codeforces i SWE-Bench rozwiązał 49,2% przypadków, co było wyższym wynikiem w porównaniu do wersji V3. Wyniki te sugerują, iż model ten sprawdzi się w zadaniach inżynierskich [29].

- Qwen

Qwen to model językowy, stworzony przez zespół badawczy Alibaba Group, udostępniany w ramach otwartej licencji. Model Qwen został opracowany tak, aby cechował się dużą skalowalnością, wydajnością obliczeniową oraz dostosowaniem do ludzkich preferencji językowych [31].

Podstawowa wersja Qwen to Qwen-7B oraz Qwen-14B. Modele te zostały wytrenowane na zbiorze danych zawierającym nawet 3 biliony tokenów, a także obejmującym szeroki zakres źródeł, takich jak dokumenty z Internetu, kody źródłowe programów i wielu innych treści w różnych językach. Podczas uczenia modelu zwrócono uwagę szczególnie na jakość i odwzorowanie rzeczywistości danych, a cały proces został wzbogacony o dodatkową eliminację powtarzających się danych oraz filtrowanie jakościowe [31].

Model bazuje na architekturze Transformera, która inspirowana była LLaMA, czyli serią modeli opracowanych przez firmę Meta [31]. LLaMA (ang. Large Language Model Meta AI) to jedna z najpopularniejszych rodzin otwartych modeli językowych, które można uruchomić lokalnie. Dzięki udostępnieniu zarówno wag modeli, jak i kodu źródłowego, LLaMA stała się punktem wyjścia dla wielu projektów badawczych i komercyjnych, umożliwiając niezależny rozwój i wdrażanie dużych modeli językowych poza środowiskiem chmurowym [41]. Natomiast w modelu Qwen wprowadzono kilka modyfikacji m.in. Rotary Positional Embeddings (RoPE) do reprezentacji pozycji, funkcję aktywacji w celu lepszego uchwycenia nieliniowości, normalizację RMSNorm w celu poprawy efektywności, a także Flash Attention oraz LogN-Scaling, aby poprawnie przetwarzać długie konteksty [31]. Warto zauważyć, że podobnie jak LLaMA, również architektura Qwen opiera się na rozwiązaniach Transformera i rozwija je w podobnym kierunku, lecz wprowadza własne usprawnienia związane z efektywnością i przetwarzaniem kontekstu.

Uczenie modelu odbywało się w trybie autoregresyjnym, z użyciem optymalizatora AdamW oraz precyzji BFloat16, w celu usprawnienia działania na nowszym sprzęcie komputerowym. Finalnie powstały dwie wersje modelu, gdzie liczba parametrów wynosiła odpowiednio 7 i 14 miliardów, które były zróżnicowane pod względem liczby warstw, wielowątkowego mechanizmu uwagi oraz liczby jednostek w warstwach ukrytych [31].

W ramach projektu Qwen opracowano kilka wyspecjalizowanych modeli w konkretnych zastosowaniach. Pierwszym z nich jest Qwen-Chat, który został dostrojony przy użyciu metod nadzorowanego uczenia (SFT) oraz wzmacnianego uczenia z informacją zwrotną od człowieka (RLHF), co lepiej sprawdza się w komunikacji w formie dialogu. Kolejnym z modeli jest Code-Qwen, czyli wersja skoncentrowana na programowaniu. Model Code-Qwen trenowany był na dużych zbiorach, zawierających kody źródłowe programów. Z kolei Math-Qwen-Chat to model stworzony z zamiarem wykorzystania w problemach matematycznych, jego skuteczność została zweryfikowana poprzez zestawy

zadań zawarte w GSM8K i MATH. Wynik uzyskany podczas testów były zbliżone do wyniku GPT-3.5. Ostatnim z dostępnych modeli jest Qwen-VL, który potrafi analizować zarówno tekst, jak i obrazy [31].

Na podstawie testów Qwen-14B prezentuje podobną wydajność jak GPT-3.5. Uzyskał wyniki MMLU (66,3%), GSM8K (61,3%). Szczególnie zadowalające rezultaty prezentują modele Code-Qwen i Math-Qwen, które uzyskały Code-Qwen-14B wynik 66,4% w teście HumanEval, a model Math-Qwen-14B-Chat uzyskuje 60,1% skuteczności na GSM8K i 59,3% na zestawie MATH. Warto również wspomnieć, iż model Qwen ma możliwość korzystania z interpreterów kodu [31].

- Gemini

Model Gemini 2.5 Pro został zaprojektowany przez Google DeepMind w marcu 2025 roku. Jest to duży model językowy zaprojektowany do zadań wymagających złożonego rozumowania, kodowania oraz analizy danych w różnych formatach. Gemini 2.5 Pro obsługuje zarówno tekst, obraz, dźwięk oraz wideo. Architektura Gemini 2.5 Pro umożliwia przetwarzanie długich kontekstów, ponieważ został wyposażony w okno kontekstowe do 1 miliona tokenów, co umożliwiło analizę obszernych dokumentów [32] [33].

W testach porównawczych model Gemini cechował się wysoką skutecznością. W MMMU oceniającym zdolność do rozumienia złożonych danych osiągnął 81,7%. Natomiast w przypadku AIME 86,7%, a GPQA uzyskano 84%, ale w teście Humanity's Last Exam, który mierzy zdolności rozumowania w wyjątkowo wymagających zadaniach językowych, model osiągnął rezultat tylko na poziomie 18,8%, działając bez wsparcia zewnętrznych narzędzi [42].

Istotnym atutem Gemini 2.5 Pro jest jego wydajność w zadaniach związanych z programowaniem, gdzie w testach LiveCodeBench v5 osiągnął wynik 70,4%. Natomiast w teście Aider Polyglot, mierzącym skuteczność edycji kodu w różnych językach programowania, uzyskał 74%. Z kolei w SWE-bench Verified osiągnął 63.8% skuteczności. Wysokie wyniki świadczą, iż ten model może być przydatny w zadaniach związanych z programowaniem [42].

Gemini 2.5 Pro znajduje praktyczne zastosowanie w tworzeniu, modyfikacji aplikacji internetowych oraz analizie dużych zbiorów danych. System ten potrafi skutecznie generować elementy interfejsu użytkownika oraz przetwarzać dane wejściowe na postać tekstową lub graficzną, co ułatwia ich analizę i prezentację [32] [33].

Równocześnie z modelem Pro pojawiła się wersja Flash opracowana również przez Google. Gemini 2.0 Flash pojawiło się na rynku w grudniu 2024 roku, aby szybko i efektywnie operować na różnych typach danych. Podobnie do wersji Pro obsługuje wejścia tekstowe, graficzne, audio i wideo, jednak wyróżnia się dodatkową funkcjonalnością w zakresie natywnego generowania obrazów czy zamiany tekstu na mowę w wielu językach [32] [43].

Model w wersji Flash, który został zoptymalizowany pod względem responsywności nieznacznie ustępuje wersji Pro w dokładności. Model Flash oferuje opcję prezentowania własnego procesu wnioskowania tzw. Flash Thinking, umożliwiającą użytkownikowi prześledzenie kolejnych etapów rozumowania. Funkcja ta udostępnia możliwość kontroli nad działaniem modelu oraz zwiększa przejrzystość generowanych odpowiedzi [44].

W testach, model w wersji Flash wypadł pozytywnie, choć został zaprojektowany przede wszystkim z myślą o zadaniach wymagających szybkiej reakcji i nieskomplikowanego przetwarzania, zwłaszcza w kontekście interakcji z użytkownikiem. Z tego powodu model znajduje zastosowanie w aplikacjach edycji treści wizualnych oraz w systemach obsługi klienta, gdzie istotną rolę odgrywa czas [43] [45].

Oba modele stanowią dwa odmienne podejścia projektowania, gdzie pierwsze z nich zakłada budowę z myślą o precyzji, rozumowaniu i analizie długich dokumentów, natomiast drugi koncentruje się na szybkości i interaktywności w środowiskach użytkowych.

- GPT-4 (Copilot)

Microsoft 365 Copilot to narzędzie zaprojektowane przez firmę Microsoft, które wykorzystuje duże modele językowe i integrujące je z danymi użytkownika dostępnymi w ekosystemie Microsoft 365. Modelem, który wykorzystuje Copilot jest rozwiązaniem firmy OpenAI GPT-4, które jest podstawowym mechanizmem przetwarzania zapytań. Narzędzie to ma na celu wspieranie codziennych obowiązków biurowych poprzez automatyzację powtarzalnych zadań oraz generowanie trafnych treści i rekomendacji. Copilot pojawia się w takich aplikacjach jak Word, Excel, Outlook, PowerPoint czy Teams, poprawiając efektywność i oszczędzając czas użytkowników [36].

Copilot opiera swoje działanie na modelu Prometheus, który bazuje na GPT-4 wraz z integracją z danymi w postaci dokumentów, wiadomości email oraz innych elementów pochodzących z usługi Microsoft Graph w ramach konta Microsoft 365. Sztuczna inteligencja zastosowana przez Microsoft analizuje zapytania użytkownika i wykorzystuje model oraz dane z aplikacji Microsoft 365, aby wygenerować adekwatną i użyteczną odpowiedź w aplikacji, w której Copilot jest używany [36] [46].

Istotnym aspektem w architekturze jest bezpieczeństwo danych, które są przetwarzane w środowisku chmurowym Microsoft z zachowaniem odpowiednich standardów. Dane użytkownika w żaden sposób nie są przechowywane w celu trenowania modelu językowego, ponieważ Copilot pracuje w obrębie dostępnych w czasie rzeczywistym danych z konkretnego konta lub organizacji [35].

Microsoft zaprojektował Copilot zgodnie z wszelkimi regulacjami dotyczącymi ochrony danych osobowych oraz gwarantuje, iż wszystkie dyskusje z Copilotem są w pełni objęte mechanizmami audytu, rejestrowania aktywności oraz szczegółowej kontroli dostępu. Przetwarzane dane są w pełni chronione oraz szyfrowane według standardów firmy Microsoft. Zarówno użytkownicy, jak i administratorzy mogą przeglądać historię interakcji z systemem oraz kontrolować uprawnienia dostępu do danych, co sprzyja większej transparentności i lepszemu zarządzaniu informacjami [34]. Podsumowując Microsoft 365 Copilot stanowi przykład innowacyjnego zastosowania sztucznej inteligencji w codziennym środowisku pracy.

- PLLuM

Model PLLuM (Polish Large Language Universal Model) jest zaawansowanym modelem językowym opracowanym w celu obsługi polskiego języka w kontekście administracji publicznej, edukacji oraz innych sektorów publicznych. Projekt pracy nad modelem został rozpoczęty w styczniu 2024 i był finansowany przez Ministerstwo Cyfryzacji, a realizowany przez przedstawicieli jednostek naukowych, takich jak Politechnika Wrocławska, IPI PAN oraz Uniwersytet Łódzki [28].

PLLuM został skonstruowany na bazie architektury Transformerów, gdzie pierwszym z etapów był trening bazowego modelu językowego oraz kolejno jego dostrajanie do formy dialogowej, obejmującej interakcje z człowiekiem [47]. Szczególną uwagę zwrócono na trafność odpowiedzi, zgodność z intencją użytkownika i eliminację halucynacji językowych.

Głównym aspektem projektu była jakość danych treningowych, które składają się z wielomiliardowego zbioru tekstów z różnych gatunków czy rejestrów języka polskiego m.in. poprzez teksty literackie, naukowe, prawne, ale także mowę potoczną i dane w językach słowiańskich i angielskim. Taki szeroki zakres materiałów umożliwia przetwarzanie polszczyzny w wielu kontekstach [48].

Uzyskanie danych do modelu było w pełni zgodne z prawem oraz zasadami etycznymi. Dane były pobierane na zasadach dobrowolnych umów licencyjnych od wydawców, ale także zostały wzbogacone o publiczne repozytoria i wcześniejsze projekty badawcze. Całość procesu była zgodna z europejskimi regulacjami dotyczącymi AI i praw autorskich [49].

Równolegle prowadzono proces uczenia modelu, który polegał na dostrajaniu przy pomocy zestawu instrukcji oraz danych odnośnie preferencji. To pozwalało na uzyskanie bardziej trafnych i naturalnych odpowiedzi w języku polskim [50]. Dodatkowo stworzono moduł asystenta użytkownika, który integruje model językowy z bazą danych na temat wiedzy urzędowej, wspierając użytkowników w zadaniach administracyjnych [47]. Model zgodnie z przyjętą wizją ma nie tylko działać jako narzędzie przetwarzające język naturalny, ale także rozwijać polski sektor technologiczny w sferze AI.

Współczesne modele językowe i generatywne są istotnym elementem wielu zaawansowanych systemów opartych na sztucznej inteligencji. Jednym z najbardziej wpływowych modeli językowych ostatnich lat jest GPT-4, opracowany przez OpenAI, który został wdrożony w wielu zastosowaniach praktycznych, w tym w narzędziach komercyjnych takich jak Microsoft 365 Copilot. Inne alternatywne rozwiązania stosowane w modelach, takich jak PLLuM, DeepSeek, Qwen czy Gemini, które zostały opracowane przez zespoły badawcze i duże korporacje technologiczne, pokazują różnorodne podejście do przetwarzania języka naturalnego.

Modele generatywne coraz częściej obejmują nie tylko tekst, lecz również inne formy twórczości cyfrowej. Obok najbardziej popularnych modeli rozwijane są również systemy generujące różnorodne treści multimedialne. DALL-E jest to model zaprojektowany przez OpenAI, służący do generowania obrazów na podstawie opisu słownego, często o wysokim poziomie szczegółowości i kreatywności. Natomiast Bing Image Creator jest to narzędzie od Microsoftu, które udostępnia tę technologię w prostym interfejsie przeglądarkowym, umożliwiając generowanie grafiki bez użycia skomplikowanej wiedzy [51] [52]. W obszarze muzyki Suno umożliwia tworzenie autorskich utworów na podstawie wprowadzonego opisu piosenki. System ten bazuje na modelach generatywnych, które przetwarzają język naturalny na ścieżkę dźwiękową [53]. Podobne podejście stosuje narzędzie firmy OpenAI Sora, która przekształca opisy tekstowe w sekwencje wideo, tworząc realistyczne, dynamiczne obrazy, które mogą być wykorzystywane w różnych produkcjach filmowych [54]. Z kolei innym przykładem jest SayMotion wyprodukowane przez firmę DeepMotion, czyli narzędzie służące do generowania animacji na podstawie tekstu. Takie rozwiązanie może wesprzeć rozwój obszarów artystycznych czy prezentacji poprzez szybką wizualizację pomysłów [55].

2.4. Zastosowanie istniejących rozwiązań sztucznej inteligencji i ich rola w codziennym życiu.

Sztuczna inteligencja odgrywa istotną rolę w życiu codziennym, stając się nieodzownym elementem współczesnej ludzkości. AI znajduje zastosowanie w wielu sektorach, rozpoczynając od ochrony zdrowia, przez logistykę, aż po edukację, kulturę i prawo. Choć rozwój technologii obejmuje różne obszary, to w ostatnich latach szczególne znaczenie zyskały modele językowe, które coraz częściej wspierają lub zastępują tradycyjne rozwiązania.

W sferze medycznej, choć dominującą rolę odgrywa komputerowe rozpoznawanie obrazu, warto zauważyć, że również modele językowe zaczynają wspierać lekarzy m.in.: w analizie dokumentacji medycznej, automatycznym generowaniu raportów, czy wspomaganiu diagnostyki poprzez interpretację danych opisowych. Dotychczas jednak najwięcej badań koncentruje się na wykorzystaniu algorytmów głębokiego uczenia w diagnostyce obrazowej. Przykładem może być wykrywanie zapalenia płuc, rozedmy płuc, czy zmian nowotworowych na podstawie obrazów RTG i tomografii komputerowej, z wykorzystaniem sieci neuronowych. Diagnoza zapalenia płuc osiągnęła współczynnik AUC na poziomie 0,81 do nawet 0,97, co może być porównywalne z wynikami doświadczonych radiologów [56]. Kolejnym z przykładowych rozwiązań jest automatyczna analiza obrazów w celu oceny rozedmy płuc, gdzie wyniki korelowały z wynikami klasycznych badań spirometrycznych [56]. Takie podejścia, choć wizualne, często wspierane są opisami generowanymi przez systemy NLP, co łączy je z modelami językowymi.

W przypadku logistyki, poza typowym zastosowaniem AI w celu optymalizacji tras, czy analizy kosztów, coraz powszechniejsze staje się wykorzystywanie modeli językowych. Modele te są wykorzystywane do analizy opinii klientów, generowania automatycznych raportów oraz zarządzania komunikacją z klientami za pomocą chatbotów. Przykładem zastosowania może być wykorzystanie sieci neuronowej do oceny usług transportowych w jednej z firm, gdzie wzięto pod uwagę takie kryteria jak terminowość, koszt, bezpieczeństwo, czy wpływ na środowisko. Badania wykazały, iż sieci neuronowe osiągnęły skuteczność na poziomie 95-99%, co potwierdza ich wartość w praktyce [57]. Zastosowanie technologii AI przez firmy działające w obszarze logistyki umożliwia szybszą reakcję na zakłócenia w łańcuchu dostaw oraz usprawniają komunikację z klientami, przez co zwiększa się efektywność transportu.

W obecnych czasach rozwiązania wykorzystujące AI pojawiają się w codziennym życiu ludzi. Sztuczna inteligencja wykorzystywana jest jako system do rekomendacji na platformach takich jak Netflix lub Youtube, w asystentach głosowych (Google Assistant, Siri), w tłumaczach językowych (DeepL, Google Translate), ale także w aplikacjach kontrolujących parametry życiowe [58]. Dzięki wykorzystaniu dużych modeli językowych, systemy te potrafią przetwarzać język naturalny, interpretować intencje użytkownika oraz w odpowiedni sposób reagować, co zwiększa satysfakcję wśród użytkowników.

Postrzeganie AI przez społeczeństwo jest związane z funkcjonalnością tej technologii m.in. ludzie postrzegają sztuczną inteligencję jako wygodę, poprawę jakości życia, a także możliwość lepszej organizacji swojego czasu wolnego. Jednak pojawiają się również obawy społeczeństwa, co do dehumanizacji oraz utraty kontroli nad tą technologią. AI coraz częściej wnika w przyzwyczajenia oraz sposób poznawania świata poprzez personalizowane treści, automatyczne moderowanie czy interaktywne media [58].

Reasumując, zastosowanie sztucznej inteligencji w codziennym życiu nie jest tylko prognozą, lecz rzeczywistością. Technologia coraz częściej pojawia się w wielu sektorach publicznych, a także zyskuje większą aprobatę wśród społeczeństwa. Jej przenikanie w dziedzinę medycyny, logistyki i transportu, a także edukacji, czy kultury wspiera ludzką działalność, aby zautomatyzować procesy i pomagać w podejmowaniu trafnych decyzji. Jednocześnie należy pamiętać, iż technologia ta wymaga odpowiedzialnego podejścia i regulacji dla dobra ogółu.

3. Rola kontekstu zawartego w pytaniach i zadaniach w generowaniu odpowiedzi przez modele AI

Wraz z rozwojem modeli językowych opartych na sieciach neuronowych, coraz większe znaczenie ma sposób, w jaki formułowane są pytania oraz jakie informacje towarzyszą wprowadzanym poleceniom. Jednym z czynników wpływających na jakość i skuteczność generowanych odpowiedzi jest kontekst, zarówno w odniesieniu do bezpośredniego sensu wynikającego z treści pytania, jak i do wcześniejszego przebiegu rozmowy, który może być uwzględniany przez model językowy. W tym rozdziale zostanie poruszone, czym właściwie jest kontekst w przetwarzaniu języka naturalnego, jakie może on przybierać formy oraz jak wpływa na funkcjonowanie modeli, co jest szczególnie istotne w korzystaniu z tej technologii. Przeanalizowane zostaną przykłady wpływu kontekstu na odpowiedzi generowane przez modele językowe, a także określone zostaną trudności, które napotykają modele językowe w interpretacji zapytań oraz treści wprowadzanych przez użytkowników, co często prowadzi do błędnych odpowiedzi.

3.1. Definicja kontekstu oraz jego rodzaje w przetwarzaniu języka naturalnego

Kontekst w dziedzinie przetwarzania języka naturalnego stanowi zbiór informacji, które wpływają na sposób interpretacji instrukcji wprowadzanej przez użytkownika. Modele generatywne w oparciu o dane wejściowe wraz z ich kontekstem generują odpowiedzi. W celu wygenerowania treści wykorzystują najbardziej prawdopodobne kolejne słowo zgodnie z pewnymi wzorcami uzyskanymi w procesie szkolenia. Rozszerzony kontekst w zapytaniach często przekłada się na znaczącą poprawę jakości oraz personalizację otrzymanych odpowiedzi [3].

W literaturze można wyodrębnić kilka rodzajów kontekstu wykorzystywanego przez modele językowe:

- Kontekst lokalny - odnosi się do słów i zdań z najbliższego otoczenia w obrębie jednej sekwencji tekstowej. Na podstawie którego modele językowe przewidują kolejne tokeny, będące istotnym elementem działania autoregresyjnej architektury pojawiającej się w modelach takich jak GPT [59].
- Kontekst dyskursywny - obejmuje dłuższe fragmenty historii rozmów, które umożliwiają modelom zachowanie spójności wypowiedzi oraz odwołanie się do wcześniej wspomnianych informacji w tekście. Modele generatywne są w stanie wykorzystywać takie informacje w ramach tzw. in-context learning [4].
- Kontekst użytkownika - dane dotyczące osoby korzystającej z modelu, które mogą determinować styl oraz poziom wypowiedzi. Odpowiedzi te mogą być modulowane przez techniki takie jak Context Steering, umożliwiające precyzyjne sterowanie pod wpływem kontekstu [60].

- Kontekst zadaniowy – obejmuje informacje o celu zapytania. Modele typu few-shot są w stanie dostosowywać odpowiedź do stylu i celu po wcześniej zaprezentowanych zadaniach [59].
- Kontekst zewnętrzny – odnosi się do informacji spoza aktualnego zapytania, które mogą być pobierane z zewnętrznych źródeł. Integracja tego typu rozwiązań znacząco poprawia trafność generowania odpowiedzi szczególnie w zadaniach wymagających specjalistycznej wiedzy [61].

Wykorzystywanie kontekstu przez modele językowe jest kluczowym czynnikiem wpływającym na jakość generowanych treści. Nieprecyzyjne lub niewystarczające podanie kontekstu może utrudniać modelowi interpretację zapytania, co z kolei zwiększa ryzyko wystąpienia tzw. halucynacji lub generowania zbyt ogólnych odpowiedzi [4] [60]. Halucynacje wynikają ze sposobu działania samych modeli, jednak właściwe użycie kontekstu może znacząco zminimalizować ich występowanie. Reasumując długość kontekstu, jak i jego typ wpływa na sposób interpretacji zapytania i dobierania odpowiednich informacji i narzędzi przy generowaniu odpowiedzi.

3.2. Znaczenie treści i precyzji zapytań na generowane odpowiedzi przez modele AI

Skuteczność modeli językowych w generowaniu odpowiedzi w dużej mierze zależy od jakości oraz precyzji formułowanych zapytań. Precyzyjne, jak i zawierające trafny kontekst pytania umożliwiają dokładniejsze zrozumienie intencji użytkownika, co skutkuje uzyskaniem bardziej trafnych i relewantnych odpowiedzi.

Badania pokazują, iż odpowiednio sformułowane zapytania pozwalają w pełni wykorzystać potencjał modeli AI. Model takie jak GPT czy LLaMA wykazują wyższą skuteczność, gdy zapytania zawierają odpowiednią ilość informacji na temat kontekstu lub są wspomagane przykładami [59]. Przykładem może być użytkownik, który formułuje ogólne zapytanie, co skutkuje wygenerowaniem przez model zbyt ogólnej odpowiedzi lub niespójną odpowiedź pod względem zawartości szczegółów. Jednak, jeśli w zapytaniu wprowadzono dodatkowy kontekst, otrzymana odpowiedź będzie spersonalizowana do poziomu poznawczego odbiorcy [60].

Zastosowanie kontekstu pozwala na bardziej trafne dopasowanie generowanej treści w odpowiedzi na pytanie wprowadzone do modelu. Poprzez techniki, takie jak sterowanie kontekstem (ang. context steering) możliwa jest zmiana siły wpływu dodatkowej informacji na ostateczną odpowiedź. W technikach tego typu stosuje się współczynnik regulacyjny λ , określający siłę wpływu kontekstu na proces generowania. Modyfikacja tego parametru pozwala generować odpowiedzi bardziej spersonalizowane lub bardziej ogólne, w zależności od potrzeb [60]. Natomiast dekodowanie z uwzględnieniem wpływu kontekstu (ang. context influence decoding, CID) wykorzystuje punktową informację wzajemną (ang. Pointwise Mutual Information, PMI) do kalkulowania, w jakim stopniu kontekst wpływa na wybór kolejnego tokena podczas generowania. Za pomocą tej metody można nie tylko zwiększać trafność, ale także zmniejszać liczbę wystąpień wygenerowanych, niespójnych informacji w stosunku do danych wejściowych [4].

Zbyt ogólne, niekompletne lub niejednoznaczne zapytania mogą prowadzić do otrzymania odpowiedzi błędnych, nieadekwatnych lub pozbawionych sensu. Ponadto, brak kontekstu może skutkować tym, iż model zbyt mocno opiera się na wstępnej wiedzy, co zwiększa ryzyko halucynacji [4].

Precyzja i jakość kierowanych zapytań do modeli językowych mają fundamentalne znaczenie dla jakości otrzymanych odpowiedzi. Wykorzystanie kontekstu, jasne określenie celu oraz stosowanie przykładów w zapytaniach skutkuje zarówno poprawą trafności odpowiedzi oraz ograniczeniem błędów modelu. Metody takie jak context steering czy CID, umożliwiają pewną kontrolę wpływu kontekstu, co czyni modele bardziej użytecznymi w praktyce.

3.3. Trudności w zrozumieniu zapytań i zadań przez modele językowe

Jednym z głównych wyzwań w korzystaniu z wybranych modeli są halucynacje występujące w wygenerowanych odpowiedziach, które wynikają z wielu czynników m.in.:

- Braku konkretów i sprecyzowania problemu w zapytaniu – prompt nie precyzuje jednoznacznie, czego użytkownik oczekuje, co utrudnia modelom właściwą interpretację.
- Niepełnego lub niejasnego kontekstu w danych wejściowych – ograniczona ilość kontekstu powoduje błędy w zrozumieniu potrzeb użytkownika przez model.
- Pojawiających się niejednoznaczności w treści – wieloznaczeniowe wyrażenia uniemożliwiają rozpoznanie intencji użytkownika
- Złożona lub nieczytelna konstrukcja zapytania – nadmiernie rozbudowane lub chaotyczne polecenia uniemożliwiają generację trafnych i zwięzłych odpowiedzi.
- Brak świadomości na temat danych treningowych – dane uczące mogą być błędne lub stronnicze ze względu na informacje zawarte w obszernych zbiorach danych. [3]

Mimo ciągłego rozwoju modeli nadal istnieją trudności w związku z poprawną interpretacją zapytań formułowanych przez użytkowników. Choć modele osiągają stosunkowo wysoką skuteczność w wielu zadaniach w zakresie przetwarzania języka naturalnego, ich rozumienie poleceń wciąż bywa ograniczone, szczególnie w przypadku nieprecyzyjnych lub niekompletnych komunikatów. Jednym z głównych problemów jest brak pełnego zrozumienia intencji użytkownika w przypadku, gdy zapytanie zawiera niejasne sformułowania lub zbyt ogólny kontekst. Modele często generują odpowiedzi bazujące na najbardziej prawdopodobnych wzorcach, co może prowadzić do halucynacji [4].

Kolejną trudnością jest odpowiednie zidentyfikowanie celu zapytania, zwłaszcza, gdy użytkownik nie określa wyraźnie, czy oczekuje definicji, przykładu czy pewnej argumentacji. Bez sprecyzowanego kontekstu model może wybrać niewłaściwą formę wypowiedzi, co obniża trafność odpowiedzi. Ponadto, w sytuacjach wymagających specjalistycznej wiedzy lub rozumowania abstrakcyjnego, modele mogą mieć pewne problemy z prawidłową interpretacją specjalistycznych terminów lub zwrotów językowych [60].

Warto również zauważyć, iż modele mają trudności w przetwarzaniu skomplikowanych struktur logicznych, wieloetapowych poleceń lub zapytań wymagających wnioskowania. Fragmenty odpowiedzi mogą być niespójne lub zbyt uproszczone, co wynika z faktu, iż modele operują na statystycznych zależnościach w danych, a nie semantycznym rozumieniu znaczenia zdań [59] [62].

Podsumowując, trudności w zrozumieniu zapytań i treści przez modele językowe są jednym z istotnych przyczyn halucynacji. Praca nad poprawą precyzji zapytań, wzmacnianiem kontekstu oraz rozwijaniem technik dekodowania ma kluczowe znaczenie dla zwiększania trafności i wiarygodności generowanych odpowiedzi.

4. Metodologia badawcza

W celu zapewnienia merytorycznej poprawności oraz wiarygodności przeprowadzonych badań szczegółowo opracowano strukturę metodologii badawczej. W niniejszym rozdziale scharakteryzowano cały proces badawczy, rozpoczynając od koncepcji i sposobu organizacji badań, przez wybór niezbędnych narzędzi, aż po zastosowane metody analizy danych na temat wpływu kontekstu w narzędziach AI. Zaprezentowano również uzasadnienie wyboru danej formy badania i szczegóły odnośnie ich realizacji. Uwzględniono sposób doboru grupy użytkowników i modeli oraz ich opis, a także scharakteryzowano narzędzie badawcze m.in. służące do tworzenia i przeprowadzania ankiet i do porównania wybranych modeli. Opisano również zapytania oraz zadania wprowadzane do narzędzi AI oraz metody wykorzystane podczas eksperymentu w celu interpretacji wyników.

4.1. Charakterystyka badań

Badania miały charakter złożony i wieloetapowy ze względu na zawartość aspektu ilościowego, jak i jakościowego, co umożliwiło kompleksowe spojrzenie na analizowane zagadnienie. Zastosowanie dwóch strategii badań pozwoliło na przeprowadzenie oceny konkretnych parametrów technicznych, ale również wgląd w doświadczenie i sposoby interakcji użytkowników z modelami językowymi.

W ujęciu ogólnym, badanie zostało podzielone na dwie główne części. Pierwsza część obejmowała użytkowników - ich preferencje, zachowanie w wybranych sytuacjach oraz poziom zaawansowania w używaniu narzędzi bazujących na sztucznej inteligencji. Druga część badań koncentrowała się na porównaniu różnych modeli językowych. Szczególny nacisk kładzie się na zbadanie zależności pomiędzy sposobem formułowania zapytania, a skutecznością modelu poprzez wygenerowaną treść.

Badania miały charakter porównawczy i eksploracyjny. Podczas, których uwzględniono analizę danych liczbowych i tekstowych, zastosowano metodę grupowania i redukcji wymiarów, jak również ocenę podobieństwa semantycznego i jakościowego. Część analityczna objęła również przetwarzanie danych wejściowych oraz ocenę odpowiedzi modeli pod kątem jakości oraz trafności. Uzyskane dane zostały przekształcone, uporządkowane oraz zestandaryzowane w celu poddania wyników szczegółowej analizie.

4.2. Procedura badawcza

Cały proces badawczy został zaplanowany w sposób uporządkowany i przeprowadzony zgodnie z wcześniej ustalonymi założeniami. Badania zrealizowano w kilku etapach, w których przygotowano narzędzia, jak i wykonano eksperyment oraz analizę uzyskanych danych.

W pierwszym kroku opracowano bazę pytań, która miała stanowić ustandaryzowany materiał wykorzystywany w dalszych analizach. Pytania zostały zróżnicowane pod wieloma względami m.in. długość, obecność słów kluczowych, aby możliwe było zweryfikowanie reakcji modeli AI na różne formy zapytań. Równolegle projektowano ankietę dla użytkowników narzędzi AI na temat ich doświadczenia i oczekiwań wobec narzędzi, ale także oceny wpływu kontekstu na generowane treści.

Badanie za pomocą ankiety wykonywano za pomocą formularza w formie cyfrowej, co umożliwiło szybkie zebranie danych. Dane były gromadzone anonimowo, a udział był w pełni dobrowolny. Zapewniono zróżnicowanie ankietowanych pod względem kategorii wiekowej oraz płci, co pozwoliło na przeprowadzenie bardziej zróżnicowanej próby badawczej. Natomiast w przypadku badań porównawczych modeli, każdemu z wybranych

modeli przypisano ten sam zestaw pytań, co umożliwiło zachowanie jednolitych warunków testowych. Wygenerowane odpowiedzi zostały oznaczone m.in. nazwą modelu lub wersji, co ułatwiło przeprowadzenie rzetelnej oceny ich skuteczności w generowaniu odpowiedzi z wykorzystaniem wybranych miar podobieństwa i jakości.

W kolejnym etapie w trakcie badań oceny subiektywnej zebrane informacje poddano wstępnej filtracji m.in. usunięto wartości odstające, uzupełniono brakujące dane, a także zamieniono wszystkie dane tekstowe na postać liczbową z wykorzystaniem kodowania zmiennych tekstowych oraz standaryzacji wartości. W przypadku badań metodą obiektywną w wybranych narzędziach wykorzystujących odpowiednie modele wprowadzono wcześniej sformułowane zapytania.

Kolejnym etapem w przypadku badań ankietowych było przygotowanie i wdrożenie algorytmów analitycznych. W trakcie badań wykorzystano metody statystyczne oraz algorytmy klasteryzacji, jak i analizę głównych składowych (PCA), aby wyodrębnić pewne wzorce i zależności w danych. Obliczenia i wizualizację wykonano przy użyciu odpowiedniego środowiska programistycznego oraz niezbędnych bibliotek.

Natomiast w przypadku porównania modeli, kolejny etap polegał na analizie ilościowej i jakościowej danych tekstowych za pomocą metryk takich jak BLEU, ROUGE, BERTScore, czy wskaźnik unikalnych tokenów. Uzyskane wyniki zostały porównane między sobą pod względem spójności, trafności oraz długości generowanych treści.

Wszystkie działania w ramach badań zostały wykonane zgodnie z zasadami etycznymi. Poza tym wyniki oraz wnioski uzyskane podczas badań umożliwiły opracowanie praktycznych rekomendacji w zakresie optymalnego korzystania z narzędzi AI opartych na modelach językowych.

4.3. Opis i konstrukcja ankiety badawczej

W celu zgromadzenia empirycznych danych na potrzeby pracy dyplomowej opracowano formularz w postaci ankiety badawczej, który został stworzony za pośrednictwem platformy Google Forms. Głównym celem ankiety było zbadanie wpływu kontekstu na generowane odpowiedzi w opinii użytkowników, ale także poznanie poziomu zaawansowania użytkowników, ich opinie oraz sposób korzystania z narzędzi opartych na sztucznej inteligencji.

Ankieta została zaprojektowana w sposób umożliwiający zebranie zarówno danych ilościowych, jak i jakościowych. Składa się łącznie z 27 pytań, które można podzielić na trzy części:

- Dane na temat osoby ankietowanej - czyli pytania odnośnie płci oraz przedziału wiekowego, co umożliwiło określenie profilu demograficznego uczestników badania.
- Zachowania oraz doświadczenia związane z AI - ta część ankiety obejmowała pytania zamknięte oraz półotwarte dotyczące częstotliwości i celu korzystania z narzędzi AI, sposobu formułowania zapytań, modyfikowania w przypadku niezadowolających odpowiedzi, a także subiektywnej oceny jakości odpowiedzi udzielanych przez systemy sztucznej inteligencji. Pytania te pozwoliły zidentyfikować zachowania użytkowników oraz ich oczekiwania wobec technologii.

- Eksperymentalna ocena wpływu kontekstu i formy pytania na odpowiedzi AI - ten blok w ankiecie obejmował zestaw odpowiedzi wygenerowanych przez AI na podstawie różnych wariantów zapytań. Do ich przygotowania wykorzystano modele GPT-4o i o4-mini (odpowiedzi tekstowe), a także narzędzie Bing Image Creator (obrazy). W każdej parze odpowiedzi uwzględniono również typ kontekstu – odpowiedzi były generowane bez kontekstu lub z jego rozszerzoną wersją. Zadaniem ankietowanych było wskazanie, która odpowiedź zawiera bardziej szczegółowe informacje lub odznacza się wyższym poziomem jakości. Zastosowano tu m.in. pytania z oceną w skali numerycznej od 1 do 10 oraz pytania wyboru bazujące na analizie tekstów, grafik oraz konspektów.


W ankiecie zastosowano czytelny i prosty język, by pytania były w pełni zrozumiałe dla wszystkich ankietowanych. Ankieta była w pełni anonimowa, a uzyskane dane zostały wykorzystane do celów badawczych.

4.4. Dobór i opis uczestników badania

Badanie zostało przeprowadzone z udziałem 80 ankietowanych, którzy wypełnili ankietę w formie online udostępnioną za pośrednictwem Google Forms. Kolejność pytań w ankiecie była identyczna dla wszystkich ankietowanych, aby zachować spójność pytań. Ankieta skierowana była do osób korzystających z narzędzi opartych na AI lub wykazujących zainteresowanie tą tematyką.

W badaniu wzięło udział niemal równa liczba kobiet i mężczyzn. Zgodnie z wynikami:

1. Płeć
80 odpowiedzi




Wykres 4.1 Struktura płciowa uczestników badania

Taki rozkład zapewnia względną równowagę płci, co korzystnie wpływa na reprezentatywność uzyskanych danych i umożliwia porównania pomiędzy grupami.

Ankietowani reprezentowali zróżnicowane kategorie wiekowe. Najliczniejszą grupą były osoby w wieku 24-34 lata (30%), co może świadczyć o wysokim poziomie zainteresowania przedstawicieli młodszych pokoleń nowymi technologiami. Pozostałe grupy wiekowe przedstawiały się następująco:

2. Jaką kategorię wiekową reprezentujesz ?

80 odpowiedzi



Wykres 4.2 Struktura wiekowa uczestników badania

Struktura wiekowa wskazuje na dominację osób młodych i w średnim wieku, co jest zgodne z obserwacją, iż grupy demograficzne w granicach wieku 18-44 najczęściej korzystają z nowych rozwiązań technologicznych, w tym również sztucznej inteligencji.

4.5. Modele AI wykorzystane w analizie porównawczej

W analizie porównawczej wykorzystano najnowsze z obecnie dostępnych modeli językowych, reprezentujących różne poziomy zaawansowania technologicznego. Modele zostały wybrane w sposób umożliwiający ocenę ich skuteczności językowej oraz efektywności działania w różnych zastosowaniach praktycznych. Badaniem objęto zarówno modele opracowane przez OpenAI, jak i rozwiązania konkurencyjne.

Analizie poddano następujące modele:

- GPT-4.5,
- GPT-4o
- o4-mini
- o4-mini-high
- o3
- PLLuM 8x7B
- DeepSeek-V3
- Qwen3-235B-A22B
- Gemini 2.5 Flash
- GPT-4 (Copilot)

Modele te zostały przetestowane w identycznych warunkach eksperymentalnych, co umożliwiło porównanie ich wydajności w kontekście zdefiniowanych kryteriów oceny. Zestaw wybranych modeli umożliwił znalezienie różnic w zakresie dokładności, spójności oraz ogólnej przydatności modeli w zadaniach przetwarzania języka naturalnego.

4.6. Zestaw pytań oraz zadań użytych w badaniu

Na potrzeby badań został przygotowany zestaw pytań i zadań testowych, który obejmował różne obszary tematyczne oraz poziomy trudności. Pytania zostały posortowane według kategorii merytorycznych, typu kontekstu, długości zapytania czy obecności słów kluczowych, co umożliwiło szczegółowe porównanie działania modeli językowych w różnych warunkach testowych.

W badaniu wykorzystano pytania z następujących kategorii: wiedza ogólna, programowanie, medycyna, ekonomia. Każde z pytań zostało przyporządkowane do jednej z trzech klas długości: krótkie, średnie oraz długie. Ponadto określony został typ kontekstu – jego brak, kontekst skrócony lub rozszerzony, a także wskazano, czy dane pytanie posiada istotne słowa kluczowe, sugerujące oczekiwany zakres odpowiedzi. Pytania zostały skonstruowane, tak aby uwzględniały proste zapytania, jak i bardziej złożone polecenia, które wymagają zawansowanej interpretacji i argumentacji. Zastosowanie takiego podejścia umożliwiło sprawdzenie, jak poszczególne modele radzą sobie w zadaniach zróżnicowanych nie tylko pod względem tematyki, ale także struktury językowej.

Zestaw pytań obejmował pytania zróżnicowane pod względem:

- Obszaru wiedzy
- Stylu pytania
- Złożoności problemu

Taka analiza umożliwiła przeprowadzenie analizy skuteczności badanych modeli AI w zadaniach z zakresu przetwarzania języka naturalnego.

4.7. Metody analizy danych uzyskanych w trakcie badań

Podczas analizy danych uzyskanych w trakcie badań zastosowano szereg metod statystycznych i obliczeniowych, które miały na celu uzyskanie pewnych struktur oraz zależności pomiędzy nimi. Proces klasteryzacji był kluczowym etapem, mającym na celu identyfikację grup użytkowników. W tym procesie zastosowano nienadzorowaną metodę grupowania z wykorzystaniem algorytmu KMeans wraz z doбором parametru K za pomocą metody łokcia. Polegała ona na analizie zmniejszającej się sumy kwadratów błędów w zależności od liczby klastrów.

Aby ocenić jakość klasteryzacji, wykorzystano zestaw miar statystycznych, takich jak Silhouette Score, współczynnik Calinskiego–Harabasha oraz indeks Daviesa–Bouldina. Każda z tych metryk dostarcza informacji na temat spójności i odrębności klastrów, co umożliwiło uzyskanie bardziej wiarygodnej oceny rezultatów grupowania. W trakcie badań zastosowano również analizę korelacji między cechami opisującymi dane, co daje możliwość identyfikacji skorelowanych atrybutów oraz potencjalnej redundancji. Uzupełnieniem tej analizy było stworzenie mapy podobieństwa pomiędzy obiektami z zastosowaniem odpowiednich metryk odległości m.in.: euklidesowej, cosinusowej oraz Manhattan.

W celu pogłębienia analizy klasteryzacji zastosowano ocenę wariancji wewnątrz poszczególnych klastrów, która wskazuje, jak jednorodne są grupy stworzone przez algorytm. Do wizualizacji zastosowano metodę redukcji wymiarowości PCA, co ułatwia interpretację przestrzennego rozkładu danych i struktur klastrowych. Dodatkowo w kontekście relacji pomiędzy użytkownikami skonstruowano graf podobieństwa, w którym węzły reprezentowały jednostki badań, a krawędzie stopień podobieństwa, co umożliwiło

identyfikacje w sieci tzw. hubów, czyli centralnych punktów sieci, posiadających wysoki stopień połączeń. Świadczy to o istotnej roli w badanym zbiorze.

W przypadku badań porównania modeli generatywnych zastosowano rozbudowany zestaw metryk tekstowych. Uwzględniono w nich takie miary podobieństwa jak: podobieństwo cosinusowe, Jaccarda, ROUGE, BLEU oraz BERTScore. Umożliwiają one ocenę jakości generowanego tekstu, względem treści referencyjnych. Ponadto analizowano różnice w długości generowanych odpowiedzi, jak również ich wartość informacyjną mierzoną m.in. poprzez liczbę unikalnych tokenów, co pozwoliło ocenić różnorodność oraz zasób użytych wyrażen w odpowiedziach wygenerowanych przez modele AI.


5. Wyniki przeprowadzonych badań

W niniejszym rozdziale zaprezentowano wyniki badań przeprowadzonych w ramach pracy magisterskiej, których celem była ocena skuteczności modeli w generowaniu odpowiedzi przez narzędzia AI. Zgromadzone wyniki badań zostały podzielone na trzy główne obszary analizy. W pierwszej kolejności przedstawione zostały wyniki ankiety, której uczestnicy oceniali jakość odpowiedzi dostarczonych przez narzędzia AI. Następnie przedstawiono porównanie skuteczności modeli w postaci wykresów. Kończącą część rozdziału wzbogacono o szczegółowe wyniki ułatwiające interpretację wyników uzyskanych w ankietach.

5.1. Wyniki ankiety dotyczącej oceny jakości odpowiedzi wygenerowanych przez różne narzędzia AI

W ramach przeprowadzonych badań ankietowych zebrano odpowiedzi od 80 uczestników, którzy oceniali jakość i przydatność odpowiedzi wygenerowanych przez narzędzia sztucznej inteligencji. Celem badania było poznanie rzeczywistych doświadczeń użytkowników z systemami AI, takimi jak ChatGPT, Google Assistant i inne, ze szczególnym uwzględnieniem kwestii kontekstu, trafności oraz zaufania do udzielanych odpowiedzi. Poniżej zaprezentowano wyniki dla poszczególnych pytań wraz z krótką analizą.

3. Jak często korzystasz z narzędzi opartych na sztucznej inteligencji (np. ChatGPT, Luna, Google Assistant, itp.) ?
80 odpowiedzi




Wykres 5.1 Częstotliwość korzystania z narzędzi AI

Na podstawie zebranych danych większość respondentów deklaruje regularne korzystanie z narzędzi opartych na sztucznej inteligencji. Najwięcej osób (33,8%) używa ich kilka razy w tygodniu, a 28,7% kilka razy w miesiącu. Codzienne użytkowanie zgłosiło 22,5% uczestników. Tylko niewielki odsetek badanych (15%) korzysta z AI rzadko, natomiast nikt nie zadeklarował całkowitej rezygnacji z takich narzędzi.

4. W jakim celu najczęściej korzystasz ze sztucznej inteligencji ?

80 odpowiedzi




Wykres 5.2 Główne cele korzystania z AI

Najczęstszym powodem wykorzystywania systemów AI jest edukacja (32,5%). Kolejne miejsce zajmuje rozrywka (26,3%) oraz wykorzystanie w pracy lub obowiązkach zawodowych (16,2%). Niektórzy respondenci wskazali również tworzenie treści lub wsparcie w codziennych obowiązkach.

5. Czy zauważasz różnice w jakości generowanych odpowiedzi AI w zależności od sposobu sformułowania pytania ?

80 odpowiedzi




Wykres 5.3 Zależność jakości odpowiedzi od formy pytania

Aż 41,3% ankietowanych zdecydowanie zauważa różnice pomiędzy odpowiedziami AI w zależności od sposobu formułowania pytań. Kolejne 31,3% zgadza się z tą tezą w umiarkowany stopniu. Natomiast tylko 16,2% ankietowanych twierdzi, iż raczej nie dostrzega takiej zależności.

6. Jak oceniasz wpływ kontekstu na jakość generowanych odpowiedzi przez systemy AI ?

80 odpowiedzi




Wykres 5.4 Ocena wpływu kontekstu na jakość odpowiedzi AI

Znaczenie kontekstu zostało ocenione jako istotne przez większość badanych. Ponad 46% wskazało, że kontekst ma duży wpływ, a 30% określiło kontekst jako czynnik mający pewien wpływ. Tylko 10% uczestników, uznało, że nie odgrywa żadnej roli.

7. Czy zmieniasz treść zapytań, jeśli odpowiedzi AI nie są zadowalające ?

80 odpowiedzi




Wykres 5.5 Reakcja użytkowników na niezadowalające odpowiedzi AI

Respondenci najczęściej podejmują próby poprawy jakości odpowiedzi przez zmianę treści pytania. 30% badanych zawsze modyfikuje zapytanie, jeśli uzyskana odpowiedź ich nie satysfakcjonuje, a 27,5% wykonuje tą operację dosyć często.

8. Czy kiedykolwiek doświadczyłeś sytuacji, w której zmiana formy pytania lub dodanie szczegółów zmieniło odpowiedź systemu AI ?

80 odpowiedzi




Wykres 5.6 Wpływ zmiany pytania na odpowiedź AI

Aż 60% uczestników ankiet przyznało, iż zdarzyła im się sytuacja, w której zmiana formy pytania istotnie wpłynęła na treść odpowiedzi wygenerowanej przez AI, a u 25% taka sytuacja nie wystąpiła.

9. Jak oceniasz użyteczność odpowiedzi udzielanych przez AI ?

80 odpowiedzi




Wykres 5.7 Ocena użyteczności odpowiedzi udzielanych przez AI

Najwięcej badanych ocenia odpowiedzi jako często trafne. Zaledwie 18,8% uważa je za zawsze użyteczne. Z kolei 23,8% określa te odpowiedzi jako średnio trafne, co sugeruje umiarkowane zadowolenie.

10. Czy uważasz, że AI lepiej odpowiada na pytania szczegółowe czy ogólne ?

80 odpowiedzi




Wykres 5.8 Preferencje użytkowników odnośnie pytań

Równe 50% osób twierdzi, że AI lepiej odpowiada na pytania szczegółowe. Dla 35% systemy AI lepiej radzą sobie z ogólnymi zapytaniem, natomiast 15% nie widzi istotnej różnicy pomiędzy pytaniami.

11. Czy uważasz, że systemy AI powinny lepiej uwzględniać kontekst wprowadzanych treści?

80 odpowiedzi




Wykres 5.9 Potrzeba lepszego uwzględniania kontekstu przez AI

Łącznie 78,8% badanych uważa, że systemy AI powinny lepiej uwzględniać kontekst treści wprowadzanych przez użytkowników. Z tego punktu widzenia można powiedzieć, iż trafność odpowiedzi nadal nie zawsze odpowiada oczekiwaniom użytkowników.

12. Jakie zmiany lub usprawnienia chciałbyś/chciałabyś zobaczyć w przyszłych systemach AI w celu poprawy uwzględniania kontekstu zapytań ?

80 odpowiedzi




Wykres 5.10 Oczekiwane usprawnienia systemów AI

Najczęściej postulowaną zmianą było umożliwienie dialogu wieloetapowego, choć dla wszystkich dostępnych usprawnień wyniki były na poziomie około 30%.

13. Czy masz jeszcze jakieś uwagi lub sugestie dotyczące sposobu, w jaki AI interpretuje i odpowiada na pytania?

80 odpowiedzi




Wykres 5.11 Sugestie użytkowników na temat interpretacji zapytań przez narzędzia AI

Tylko 45% użytkowników ma jakieś uwagi do sposobu interpretacji i odpowiedzi AI, natomiast ponad 50% nie ma żadnych uwag lub nie ma zdania na ten temat.

14. Czy masz zaufanie do odpowiedzi, które otrzymujesz od AI, gdy pytania są zadawane bez określonego kontekstu ?

80 odpowiedzi




Wykres 5.12 Zaufanie do odpowiedzi bez zawartego kontekstu

Tylko 12,5% badanych w pełni ufa odpowiedziom udzielanym przez AI bez zawartego kontekstu. 37,5% raczej posiada zaufanie do wygenerowanej odpowiedzi, ale aż 22,5% respondentów jest sceptycznie nastawiona lub zdecydowanie nie ufa takim odpowiedziom.

15. Czy uważasz, iż AI powinno posiadać zdolność interpretowania intencji pytającego na podstawie minimalnych informacji ?

80 odpowiedzi




Wykres 5.13 Interpretacja intencji przy ograniczonych danych

Ponad 2/3 uczestników badania uważa, że AI powinno być zdolne do odczytywania intencji użytkownika nawet przy niewielkiej ilości danych wejściowych.

16. Jakie są Twoje główne obawy związane z interpretacją kontekstu przez systemy AI ?

80 odpowiedzi




Wykres 5.14 Obawy w związku z interpretacją kontekstu przez systemy AI

Największą obawą użytkowników jest zbyt ogólny charakter odpowiedzi (46,3%). Kolejne wskazania dotyczyły zmiany intencji pytania przez AI (23,8%) oraz nieadekwatność odpowiedzi do zadanego pytania (30%).

17. Czy uważasz, że systemy AI powinny informować użytkownika, gdy interpretacja kontekstu może wpłynąć na odpowiedź ?

80 odpowiedzi




Wykres 5.15 Informowanie użytkownika o wpływie kontekstu na generowaną odpowiedź

Ponad 33% ankietowanych, uważa, że systemy AI powinny informować, gdy kontekst wpływa na odpowiedź. Kolejne 32,5% dopuszcza taką możliwość tylko w wybranych przypadkach.

18. Jakie elementy wprowadzonego zapytania mają według Ciebie największy wpływ na jakość odpowiedzi AI ?

80 odpowiedzi




Wykres 5.16 Elementy pytania mające wpływ na jakość odpowiedzi AI

Najczęściej wskazywanym czynnikiem był kontekst pytania (42,5%), a następnie użyte słowa kluczowe (37,5%) oraz poziom szczegółowości (33,8%).

W dalszej części badań z wykorzystaniem ankiet oceniano konkretne pary odpowiedzi wygenerowane przez systemy AI, która z nich posiadała kontekst w momencie formułowania zapytania.

19. Na podstawie poniższych odpowiedzi oceń w którym przypadku zawarto kontekst w pytaniu.


80 odpowiedzi



Wykres 5.17 Ocena kontekstu w odpowiedziach dotyczących nauki języków obcych

W tym pytaniu 57,5% uczestników wskazało odpowiedź nr 2 jako lepiej uwzględniającą kontekst pytania dotyczącego nauki języków obcych, natomiast 42,5% uznało, iż lepsza była odpowiedź 1. Wynik ten sugeruje, że użytkownicy doceniają odpowiedzi bardziej osadzone w praktycznych i społecznych aspektach tematu. Warto zaznaczyć, że to odpowiedź nr 2 zawierała kontekst w momencie formułowania zapytania, co mogło wpłynąć na jej wyższy poziom trafności według oceniających.


20. Na podstawie poniższych odpowiedzi oceń w którym przypadku zawarto kontekst w pytaniu.
80 odpowiedzi



Wykres 5.18 Ocena kontekstu w odpowiedziach dotyczących zdrowego odżywiania

W drugim przypadku 55% badanych wskazało odpowiedź 2 jako lepiej uwzględniającą kontekst, natomiast 45% wybrało odpowiedź 1. Wyniki były stosunkowo wyrównane, co może wskazywać, że obie wersje odpowiedzi były poprawnie sformułowane, ale część użytkowników oczekiwała konkretnych informacji na temat zdrowego stylu życia. Również w tym przypadku odpowiedź nr 1 została sformułowana bez uwzględniania kontekstu pytania, podczas gdy odpowiedź nr 2 powstała przy jego pełnej znajomości.


21. Na podstawie poniższych odpowiedzi oceń w którym przypadku zawarto kontekst w pytaniu.
80 odpowiedzi



Wykres 5.19 Ocena kontekstu w odpowiedziach dotyczących sztucznej inteligencji

W trzeciej parze odpowiedzi dotyczącej sztucznej inteligencji, aż 61,3% respondentów uznało, że odpowiedź 2 lepiej uwzględnia kontekst pytania, natomiast tylko 38,8% wskazało na odpowiedź 1. Takie wyniki sugerują, że ankietowani preferują odpowiedzi odnoszące się do konkretnych przykładów zastosowań w różnych dziedzinach, zamiast ogólnych opisów technologii. W tym przypadku odpowiedź nr 2 została przygotowana z uwzględnieniem kontekstu, czego nie można powiedzieć o odpowiedzi nr 1. W tym pytaniu wyraźnie zauważalna jest tendencja wyboru odpowiedzi przygotowanej z uwzględnieniem kontekstu.


22. Na podstawie poniższych odpowiedzi oceń w którym przypadku zawarto kontekst w pytaniu.
80 odpowiedzi



Wykres 5.20 Ocena kontekstu w odpowiedziach dotyczących zmian klimatycznych

Zdecydowana większość ankietowanych, czyli około 63% wskazała odpowiedź 1 jako lepszą pod kątem uwzględnienia kontekstu, a 36,3% wybrało odpowiedź 2. Przewaga pierwszej odpowiedzi może wynikać z tego, że lepiej oddawała wagę problemu globalnego ocieplenia i precyzyjniej przedstawiała jego skutki dla środowiska. Warto jednak zauważyć, iż odpowiedź nr 2 została przygotowana z uwzględnieniem kontekstu zawartego w pytaniu. Ankietowani wyraźnie wskazali poprawną odpowiedź.

23. Jakiego typu pytania formułujesz wprowadzając zapytania do systemu AI ?
80 odpowiedzi




Wykres 5.21 Typ formułowanych pytań kierowanych do systemów AI

Ankietowani częściej formułują pytania zawierające szerszy kontekst lub odniesienie do skutków („Typ 2”). Nieco mniejszy odsetek preferuje pytania bardziej ogólne („Typ 1”). Wynik ten sugeruje potrzebę do dostosowania odpowiedzi AI do bardziej złożonych zapytań.

24. Dla którego z przypadków wprowadzono bardziej szczegółowy kontekst, w jakim ten obraz miał zostać wygenerowany ?

80 odpowiedzi




Wykres 5.22 Ocena szczegółowości kontekstu przy generowaniu obrazów

W pytaniu dotyczącym promptów do generowania obrazów 57,5% badanych wskazało „Obraz nr 1” jako przykład z doprecyzowanym kontekstem. Pozostałe 42,5% uznało „Obraz nr 2” za przykład z większą liczbą szczegółów. Różnica ta podkreśla subiektywny charakter oceny kontekstu, ale ogólny trend wskazuje na większą ilość szczegółów na obrazie. Warto zaznaczyć, iż obraz nr 1 został wygenerowany na podstawie promptu uwzględniającego kontekst, natomiast obraz nr 2 powstał bez zawartości kontekstu, choć różnice w odbiorze nie były znaczące.

25. Która z wygenerowanych odpowiedzi wyróżnia się lepszą poprawnością rozwiązania?

80 odpowiedzi



Wykres 5.23 Ocena poprawności rozwiązania matematycznego

W przypadku weryfikacji poprawności rozwiązania matematycznego 56,3% respondentów wskazało odpowiedź 2 jako bardziej trafną i poprawną pod względem logicznym i rachunkowym, natomiast 43,8% uznało odpowiedź 1 za lepszą. Choć różnica nie jest drastyczna, wyniki pokazują, że użytkownicy oczekują jasnych, jednoznacznych wyjaśnień oraz poprawnej struktury obliczeń w odpowiedziach AI. Warto dodać, iż to odpowiedź nr 2 została opracowana na podstawie bardziej sprecyzowanego promptu odnośnie rozwiązania zadania, lecz różnica uzyskana w odpowiedziach użytkowników była stosunkowo niska.

26. Który z wygenerowanych konspektów maturalnych wydaje się bardziej trafny pod względem poprawności rozwiązania poniższego tematu?

80 odpowiedzi




Wykres 5.24 Ocena trafności konspektów maturalnych

Pytanie dotyczące poprawności wygenerowanych konspektów maturalnych zdecydowana większość respondentów uznała odpowiedź nr 2 (brak zawartości kontekstu w zadaniu) za bardziej trafną pod względem interpretacji tematu i zgodności z wymogami maturalnymi. Mimo, że 37,5% uczestników preferowało odpowiedź nr 1 (zawartość kontekstu w zadaniu), wyraźna przewaga drugiej propozycji świadczy o większym zaufaniu do odpowiedzi, które zawierają szczegółową analizę i szerszy kontekst literacki. Jednak zaskakujący jest fakt, iż odpowiedź nr 2 zawierała istotne błędy merytoryczne i została przygotowana bez znajomości kontekstu, co może sugerować, że respondenci kierowali się raczej formą i stylistyką wypowiedzi niż jej rzeczywistą poprawnością.

27. Jak oceniasz jakość wygenerowanej odpowiedzi przez sztuczną inteligencję na podstawie poniższego zapytania? Zapytanie: Podaj mi listę najważniejszych wydarzeń historycznych w XX wieku.

77 odpowiedzi



Wykres 5.25 Ocena jakości odpowiedzi AI na pytanie otwarte


Na zakończenie ankiety użytkownicy oceniali odpowiedź wygenerowaną przez model o4-mini na pytanie: „Podaj mi listę najważniejszych wydarzeń historycznych w XX wieku.” Ankietowani oceniali odpowiedź w skali od 1 do 10. Najwięcej osób przyznało 5 (18,2%), następnie 7 i 8 po 16,9%. Odpowiedzi ocenione na poziomie 6 i 4 uzyskały odpowiednio 15,6% i 11,7% głosów. Skrajne oceny nie zostały przyznane. Średni rozkład wskazuje na umiarkowane zadowolenie będące poprawną, lecz niezbyt szczegółową odpowiedzią.

5.2. Wyniki analizy porównawczej odpowiedzi generowanych przez różne modele AI

Celem tej części była ocena skuteczności i jakości odpowiedzi generowanych przez różne modele językowe AI, bazując na szeregu metryk ilościowych. Ocenie zostało poddane 10 modeli: 4o, Copilot (GPT-4), DeepSeek, GPT-4.5, Gemini, PLLuM, Qwen, o3, o4-mini, oraz o4-mini-high. Analiza została przeprowadzona na podstawie wyników uzyskanych dla 12 zapytań testowych, a dane zostały zaprezentowane w formie macierzy ciepłych (heatmap).

Każda z metryk przedstawiona jest jako osobna macierz, w której wiersze odpowiadają konkretnym zapytaniom, a kolumny modelom. Ciemniejsze barwy wskazują na wyższe wartości, co ułatwia wizualne porównanie skuteczności poszczególnych modeli.

W pierwszej kolejności przedstawiono analizę miary F1, która łączy w sobie zarówno precyzję, jak i czułość.




Wykres 5.26 Macierz wartości F1 dla różnych modeli AI i zapytań testowych

Najwyższy wynik F1 (0,71) został osiągnięty przez model DeepSeek w odpowiedzi na zapytanie nr 8, co wskazuje na wysoką zgodność z odpowiedzią referencyjną ocenioną za pomocą metryki BERT. Do modeli charakteryzujących się konsekwentnie wysoką jakością należą również Copilot (GPT-4), GPT-4.5, Gemini oraz Qwen.


Natomiast modele o4-mini i o4-mini-high osiągały niższe wartości F1, co sugeruje ograniczoną zdolność do generowania trafnych odpowiedzi, szczególnie w przypadku bardziej złożonych pytań. Również model o3 prezentował niższe wyniki, w niektórych przypadkach zbliżały się one do modeli wiodących, natomiast w innych wyraźnie odbiegały od średniej.

W ramach dalszej analizy porównano również czułość i precyzję za pomocą metryki BERTScore.



Wykres 5.27 Macierz wartości czułości dla wybranych modeli językowych w odpowiedzi na zapytania testowe

Przedstawione na wykresie wartości liczbowe czułości pozwalają uchwycić wszystkie istotne informacje zawarte w odpowiedzi wzorcowej. Najwyższe wartości czułości osiągnęły modele takie jak DeepSeek, GPT-4.5, PLLuM oraz Copilot (GPT-4). Modele 4o oraz Qwen szczytowy wynik osiągnęły w granicach 0,75-0,76. Szczególnie wyróżniał się model DeepSeek, który w pytaniu nr 8 osiągnął wartość 0,8, co wskazuje zdolność modelu do kompletnego odwzorowania poprawnej odpowiedzi. W przypadku modeli o4-mini, o4-mini-high oraz o3 osiągały wartość 0,7 lub niższą, co sugeruje ograniczoną zdolność pełnego wychwycenia kluczowych elementów odpowiedzi.




Wykres 5.28 Macierz wartości precyzji dla wybranych modeli językowych w odpowiedzi na zapytania testowe

Również w tym przypadku najwyższą skutecznością pod względem precyzji wykazują modele DeepSeek, GPT-4.5, PLLuM, które charakteryzują się nie tylko wysoką skutecznością w wychwytywaniu informacji, ale również precyzją w ich generowaniu. Ich

wyniki często przekraczały wartość 0,6. Najwyższy wynik odnotowano dla modelu DeepSeek, gdzie wartość wskaźnika wyniosła 0,64 dla pytania nr 8. Istotnym faktem jest, iż Gemini, mimo wysokiej czułości prezentował bardzo zróżnicowaną precyzję w przypadku niektórych pytań, gdzie uzyskiwało wartość około 0,5. Może to świadczyć o tendencji do generowania zbędnych lub mniej trafnych informacji. Wyniki te kontrastują z rezultatami osiąganymi przez modele o4-mini, o4-mini-high, a także w mniejszym stopniu z o3, które w wielu przypadkach uzyskiwały wynik na poziomie 0.48-0.51. Szczególnie niska precyzja widoczna jest dla zapytania nr 7, gdzie wszystkie modele nie przekroczyły progu 0,5, a Gemini osiągnął, wartość zaledwie 0,45.

W ramach rozszerzenia analizy porównawczej odpowiedzi generowanych przez modele językowe, uwzględniono dodatkowe miary jakości. Wygenerowane odpowiedzi przeanalizowano pod kątem ich zgodności z treścią pytania, co stanowiło wzorzec odniesienia. Poniżej zaprezentowano zestawienie wyników dla kolejnych miar jakości.


Wartości BLEU pozwalają ocenić stopień zgodności odpowiedzi modeli z referencyjnym pytaniem.



Wykres 5.29 Macierz wyników BLEU dla odpowiedzi generowanych przez wybrane modele AI

Ogólnie wartości BLEU były niskie zwykle do 0,02, co sugeruje znaczne różnice w strukturze składniowej między generowanymi odpowiedziami, a zapytaniami. Poza tym zjawisko to sugeruje brak odwzorowania stylistyki zapytania. Wyjątkiem był model GPT-4.5, który w pytaniu nr 11 osiągnął wartość na poziomie 0,03, co sugeruje większą zgodność leksykalną. Warto również wspomnieć, iż niski wynik BLEU nie musi oznaczać błędnej odpowiedzi, ale może wskazywać na parafrazowanie.

Podobieństwo cosinusowe pozwala ocenić semantyczną zbieżność odpowiedzi, co zaprezentowano na poniższym wykresie.



Wykres 5.30 Macierz podobieństwa cosinusowego między pytaniem, a odpowiedziami modeli

Modele takie jak DeepSeek, GPT-4,5, PLLuM osiągnęły lepsze rezultaty niż konkurencyjne modele, co potwierdza ich zdolność do zachowania zgodności znaczeniowej. Szczególnie wysokie wyniki zanotowano w pytaniach 5, 7, 8, 10. Odstępstwem od średniej były odpowiedzi modelu GPT-4 (Copilot) na pytanie nr 2 (0.16) i Qwen na pytanie nr 8, gdzie wartość wynosiła 0, co wskazuje na brak istotnych odniesień do treści pytania w tych przypadkach.

Metryka Jaccarda w trakcie badań wykorzystana została do porównania zbiorów tokenów odpowiedzi, gdzie jej wyniki zostały przedstawione w postaci heatmapy.




Wykres 5.31 Macierz wartości Jaccarda w celu porównania zbioru tokenów odpowiedzi

Najlepsze wyniki, na poziomie 0,06-0,08, osiągnęły modele GPT-4,5 dla pytań nr 4, 5, 6 i 11, ale także GPT-4 (Copilot) dla pytań nr 3, 6, 11 oraz 12, DeepSeek 0,06 dla pytania nr 3, a także 12. Pojedyncze wysokie wartości wskaźnika podobieństwa Jaccarda pojawiły się dla modeli 4o oraz PLLuM. Modele takie jak o4-mini i o4-mini-high częściej uzyskiwały

wartości na poziomie poniżej 0,04, co może wskazywać na mniejszą precyzję w doborze słownictwa. Szczególnie pozytywnie wyróżniało się zapytanie nr 3 w modelu 4o, gdzie uzyskano najwyższy wskaźnik, który wynosił 0,08.

Długość generowanych odpowiedzi wykazała znaczące różnice na poniższym wykresie.




Wykres 5.32 Długość odpowiedzi wygenerowanych przez poszczególne modele

Najdłuższe odpowiedzi generowały modele o4-mini oraz o3, osiągając nawet powyżej 1000 tokenów. Przykładowo w pytaniu nr 10, gdzie model o4-mini wygenerował 1167 tokenów, podczas gdy niektóre z modeli w wybranych przypadkach osiągały wyniki nie przekraczające 100 tokenów np. PLLuM, który na pytanie nr 1 wygenerował 30 tokenów. Modele takie jak GPT-4 (Copilot), GPT-4.5 charakteryzowały się bardziej umiarkowaną długością odpowiedzi, zwykle w zakresie 200-300 tokenów.

W celu pogłębionej oceny jakości generowanych odpowiedzi dokonano analizy przy użyciu miar ROUGE, które mierzą pokrycie n-gramowe względem pytania. Dodatkowo analizie poddano liczbę unikalnych tokenów jako wskaźnika różnorodności językowej generowanej wypowiedzi. Poniższe wykresy przedstawiają szczegółowe wyniki dla każdej z metryk w odniesieniu do poszczególnych modeli i zapytań testowych.


Miara ROUGE-1 pozwala ocenić, w jakim stopniu pojedyncze słowa z pytania zostały uwzględnione w odpowiedzi.



Wykres 5.33 Macierz wyników ROUGE-1 - zgodność unigramów odpowiedzi z pytaniem

GPT-4.5, GPT-4o, DeepSeek, PLLuM oraz Qwen osiągały wartości przekraczające 0,14 w pytaniach 3, 5 i 8. Najwyższy wynik o wartości 0.23 uzyskał model DeepSeek w pytaniu nr 8, co wskazuje na dużą zawartość wspólnych słów z pytaniem. Z kolei modele o4-mini i o4-mini-high osiągały wyniki zwykle w zakresie 0,03 – 0,06.


Metryka ROUGE-2, uwzględniająca pary słów, która dostarcza informacji o bardziej złożonej zgodności składniowej.



Wykres 5.34 Macierz wyników ROUGE-2 - pokrycie bigramów względem pytania

Na wykresie widoczne są najlepsze wyniki sięgające 0,18, który ponownie osiągnął DeepSeek w pytaniu nr 8, natomiast GPT-4.5 osiągnął 0,11 w pytaniach nr 5,8 i PLLuM, który uzyskał 0,11 oraz 0,13 kolejno w pytaniach 5 i 8. Wyraźnie niższe wartości odnotowano dla modeli o3, o4-mini i o4-mini-high, co może sugerować mniejsze przywiązanie do składni pytania lub większą tendencję do generowania odpowiedzi w odmiennym stylu.


ROUGE-L mierzy długość najdłuższych sekwencji tokenów, występujących zarówno w pytaniu i odpowiedzi.



Wykres 5.35 Macierz wyników ROUGE-L - zgodność najdłuższych wspólnych sekwencji tokenów

Podobnie jak w poprzednim przypadku najwyższe wartości uzyskały modele GPT-4.5, DeepSeek oraz PLLuM. Ich wartości wynosiły powyżej 0,14, kolejno w 5 i 8 pytaniu, co świadczy o wysokim poziomie ciągłości względem treści pytania. Model DeepSeek osiągnął najwyższą wartość 0,2, potwierdzając swoją skuteczność w odwołaniu do sformułowanego zapytania. Modele Gemini, o3, o4-mini oraz o4-mini-high cechowały się wyraźnie niższymi wartościami. Wartości te zwykle wynosiły mniej niż 0,06, co sugeruje mniej bezpośrednie odwołanie do pytania.

Ostatnią z analiz była miara liczby unikalnych tokenów, dostarczających informacje na temat różnorodności słownictwa wykorzystanego w generowanych odpowiedziach. Wyniki tej analizy przedstawiono w poniższej macierzy.




Wykres 5.36 Liczba unikalnych tokenów w odpowiedziach poszczególnych modeli

Największą liczbę unikalnych tokenów generował model o3, osiągając 488 unikalnych tokenów, w przypadku pytania nr 12. Równie wysokie wyniki uzyskano dla modeli m.in. Gemini, o4-mini, o4-mini-high oraz Qwen.

5.3. Zestawienie i prezentacja wyników szczegółowych

Wyniki z ankiety zostały wzbogacone o dodatkową analizę danych, której celem było pogłębienie wniosków oraz uzyskanie bardziej precyzyjnego obrazu badanej grupy. Proces analizy rozpoczęto od zaimportowania danych z pliku zawierającego odpowiedzi ankietowanych oraz dokonanie wstępnej selekcji i filtracji danych, gdyż niektóre dane nie miały znaczenia w kontekście grupowania użytkowników.

Dalszym etapem analizy było określenie optymalnej liczby grup, na które można podzielić badanych. W tym celu zastosowano metodę łokcia, polegającą na ocenie zmian wartości miary rozproszenia danych wewnątrz klastrów przy zmiennej liczbie grup. Dla każdego scenariusza w zakresie od 1 do 10 klastrów analizowano spójność danych w ramach wyodrębnionych segmentów.



Wykres 5.37 Zależność inercji od liczby klastrów (metoda łokcia)

Na podstawie wykresu zależności inercji od liczby klastrów zauważono, iż dla wartości $K=3$ występuje wyraźne załamanie krzywej, co wskazuje na optymalny podział danych na trzy grupy.

Następnie przeprowadzono klasteryzację z $K=3$, przypisując każdemu użytkownikowi klaster, do którego należy. Algorytm KMeans z powodzeniem podzielił dane na trzy grupy, co wynika z analizy wyników wskaźników walidacji jakości klasteryzacji. Przeanalizowano trzy najważniejsze metryki:

- Współczynnik Silhouette

```
Średni wskaźnik Silhouette (dla 3 klastrów): 0.1648

Średni wskaźnik Silhouette w poszczególnych klastrach:
Cluster
0      0.134578
1      0.192041
2      0.128383
```

Rysunek 5.1 Wartości dla współczynnika Silhouette

Średni wskaźnik dla całego podziału wynoszący 0,1648 wskazuje, iż klastry nie są znacząco wyraźne, co oznacza, że punkty w obrębie każdego klastra nie są w pełni skupione wokół swoich centroidów, a odległość między klastrami nie jest wystarczająco duża. W odniesieniu do poszczególnych klastrów, najlepiej widoczną separację osiągnięto w klastrze 1, jednak jego wartość jest stosunkowo niska, co może sugerować, że użytkownicy przypisani do tej grupy wykazują tylko częściowo spójne cechy. Najśłabszy wskaźnik odnotowano dla klastra 2, co może świadczyć o dużym nakładaniu się tego klastra z pozostałymi oraz o braku wyraźnych wzorców w danych przypisanych do tej grupy.

- Wskaźnik Calinski-Harabasz i wskaźnik Davies-Bouldin


```
Calinski-Harabasz Score: 19.4541
Davies-Bouldin Score:    1.8968
```

Rysunek 5.2 Wyniki wskaźników Calinski-Harabasz i Davies-Bouldin

Wynik dla wskaźnika Calinski-Harabasz, świadczy o akceptowalnym poziomie separacji między centroidami klastrów. Im wyższy wynik, tym lepiej dane są podzielone na klastry. Dla $K=3$ wynik ten był znacznie wyższy niż dla większych wartości K , co potwierdza trafność wyboru liczby klastrów.

W przypadku wskaźnika Davies-Bouldin wynik jest wartością poniżej 2, uznawanej za dobrą jakość klasteryzacji. Wskaźnik ten ocenia stosunek rozproszenia wewnątrz klastrów do odległości między klastrami - im niższa wartość, tym lepsza separacja. Wynik sugeruje, że klastry są wystarczająco kompaktowe i oddalone od siebie.


Wizualizacja wyników klasteryzacji została przeprowadzona w kilku etapach, aby lepiej zrozumieć podział danych. Na podstawie dwóch wybranych cech – $Q1$ i $Q2$ – stworzono wykres rozkładu użytkowników, który zaprezentowano na poniższym wykresie:



Wykres 5.38 Rozkład użytkowników na płaszczyźnie $Q1$ i $Q2$

Chociaż jest to ograniczone tylko do dwóch cech, podział na klastry jest już zauważalny, lecz granice między niektórymi grupami są częściowo zatarte.


W celu uwzględnienia całego spectrum zmiennych zastosowano analizę PCA (Principal Component Analysis) za pomocą której zredukowano przestrzeń danych do dwóch głównych składowych, które najlepiej reprezentują zmienność danych.



Wykres 5.39 Podział klastrów w przestrzeni głównych składowych

Na wykresie 5.39, przedstawiającym rzut danych na dwie składowe, gdzie różnokolorowe punkty reprezentują użytkowników z różnych klastrów, można zauważyć wyraźny podział na trzy grupy. Podział ten potwierdza, że algorytm poprawnie wyróżnił różnice między użytkownikami, choć widać, że klaster 2 jest bardziej rozproszony i częściowo nakłada się na pozostałe grupy, co może świadczyć o większej różnorodności ankietowanych zakwalifikowanych do tej grupy.

Macierz korelacji została opracowana, aby przeanalizować współzależność między pytaniami ankietowanych. Wizualizacja macierzy podobieństwa w formie heatmapy prezentuje się następująco:




Wykres 5.40 Macierz korelacji cech

Z analizy powyższego wykresu wynika, że większość cech nie wykazuje silnych wzajemnych zależności – współczynniki korelacji mieszczą się głównie w przedziale od -0.3 do 0.3, co oznacza, że cechy te są w dużej mierze niezależne od siebie. Wyjątek stanowią pewne pary, takie jak Q5 (różnice w jakości generowanych odpowiedzi AI w zależności od sposobu sformułowania pytania) i Q6 (wpływ kontekstu na jakość generowanych odpowiedzi przez systemy AI), które osiągają umiarkowaną korelację (ok. ± 0.5 – 0.7), co wskazuje na ich częściową współzależność.

Ponadto przeanalizowano wariację wewnątrz klastrow, co pozwoliło ustalić, które cechy najbardziej różnicują grupy użytkowników. Największe znaczenie dla podziału klastrow miały cechy Q3 (częstotliwość korzystania z narzędzi opartych na sztucznej inteligencji), Q5 (różnice w jakości generowanych odpowiedzi AI w zależności od sposobu sformułowania pytania) oraz Q7 (zmiana treści zapytań, jeśli odpowiedzi AI nie są zadowalające). Średnie wartości dla Q3 pokazują, że użytkownicy w klastrze 1 najczęściej korzystają z AI (1.3763), podczas gdy klaster 0 reprezentuje średnią częstotliwość (0.4706), a klaster 2 – okazjonalne użycie (1.1144). Cechy Q5 i Q7 również wykazują znaczące różnice – użytkownicy w klastrze 0 są najbardziej świadomi wpływu formy pytania na odpowiedzi (1.3889), natomiast klaster 2 cechuje najwyższa skłonność do modyfikowania

W celu dokładniejszej analizy utworzono graf podobieństwa, w którym każdy węzeł reprezentuje jednego użytkownika. Krawędzie między węzłami dodawano wyłącznie wtedy, gdy podobieństwo między użytkownikami przekraczało ustalony próg w tym przypadku 0.6.



Rysunek 5.3 Graf z węzłami użytkowników

W tym przypadku huby to węzły 5, 6, 7, 33 reprezentujące użytkowników, którzy mają wspólne cechy z wieloma innymi osobami, co czyni je centralnymi węzłami w analizowanej strukturze. W praktyce oznacza to, że są to osoby o uniwersalnych wzorcach zapytań lub zachowaniach, które mogą być reprezentatywne dla szerokiej grupy użytkowników.

Układ węzłów wskazuje na różnorodność klastrów oraz równomierny rozkład użytkowników w sieci. Huby, znajdujące się w różnych częściach wykresu, sugerują, że nie dominują w jednej grupie, lecz mają znaczenie dla całej struktury.

6. Analiza wyników badań

W niniejszym rozdziale przedstawiono analizę wyników uzyskanych w trakcie badań, obejmującą analizę wyników badania ankietowego, a także porównania odpowiedzi generowanych przez modele AI. Natomiast ostatnia część rozdziału stanowi omówienie czynników wpływających na zaobserwowane różnice. Analiza ta pozwala lepiej zrozumieć potencjał oraz ograniczenia badanych rozwiązań i stanowi podstawę do wyciągnięcia końcowych wniosków.

6.1. Szczegółowa analiza wyników badań ankietowych

W badaniu wzięło udział 80 uczestników, wśród których wystąpiła niemal równowaga płci, lecz mężczyźni stanowili nieznacznie większość. Najliczniejszą grupę wiekową stanowili ankietowani w wieku 24-34 lata, choć licznie reprezentowane były także osoby w wieku 18-23 lat.

Zdecydowana większość osób deklarowała korzystanie z narzędzi AI, przy czym największy odsetek osób zadeklarował ich używanie kilka razy w tygodniu. Znaczna część ankietowanych wykorzystuje te narzędzia w celach edukacyjnych, ale także zawodowych i rozrywkowych. Nieliczna grupa badanych zadeklarowała, iż nie widzi potrzeby korzystania z takich narzędzi.

Badani wykazali dużą świadomość wpływu formy zapytania na jakość odpowiedzi generowanej przez systemy AI. Większość ankietowanych przyznała, iż zmiana sformułowania pytania może wpłynąć na treść i jakość generowanej odpowiedzi. Również kontekst okazał się istotny, ponieważ przeważająca część respondentów twierdziła, iż obecność kontekstu znacząco poprawia trafność odpowiedzi.

Ankieta ujawniła, iż użytkownicy często modyfikują swoje zapytania w sytuacji, gdy początkowa odpowiedź nie jest satysfakcjonująca. Ankietowani wskazywali, iż dzieje się to „zawsze” lub „często”. Co istotne, niemal 60% badanych przyznało, że doświadczyło sytuacji, w której dodanie szczegółów lub zmiana pytania wpłynęła na treść wygenerowaną przez AI.

W ocenie ankietowanych użyteczność odpowiedzi udzielanych przez systemy AI, większość oceniła w przedziale „często trafne” do „zawsze użyteczne”, przy czym stosunkowo niewiele osób wskazywało odpowiedzi jako rzadko trafne. Na pytanie oceniające jakość konkretnej odpowiedzi AI (zapytanie o wydarzenia historyczne XX wieku), ankietowani przyznali średnią ocenę około 6,5 w dziesięciostopniowej skali, co wskazuje na umiarkowany poziom satysfakcji ze względu, iż ludzie mogą oceniać inne wydarzenia historyczne jako bardziej istotne w XX wieku.

Ankieta pozwoliła zaobserwować, iż uczestnicy są w stanie dostrzegać różnice między odpowiedziami AI, szczególnie w zakresie obecności kontekstu. W wielu przypadkach wybierali te wersje wypowiedzi, w których zawarto więcej szczegółowych informacji lub precyzyjniej określano temat. Ponadto, większość ankietowanych uznała odpowiedzi zawierające kontekst za bardziej trafne i logicznie skonstruowane.

W dalszej części analizy przeprowadzono klasteryzację, dzięki której udało się wyróżnić trzy charakterystyczne grupy użytkowników. Pierwszy klaster obejmuje osoby o średnim poziomie wiedzy technicznej. Ich zapytania były związane i rzeczowe, a odpowiedzi AI koncentrowały się na dostarczaniu podstawowych informacji. Klaster drugi grupuje użytkowników początkujących, którzy korzystają z AI przede wszystkim do prostych, codziennych zadań, takich jak szybkie porady czy organizacja dnia. Trzeci klaster

reprezentuje użytkowników zaawansowanych, formułujących zapytania, które dotyczą tematów specjalistycznych, takich jak analiza danych czy korekty kodu.

Różnice między klastrami są stosunkowo wyraźne i wskazują na zróżnicowane podejścia do interakcji z AI. Analiza wariancji wykazała, że szczególnie trzy pytania Q3 (częstotliwość korzystania z AI), Q5 (wpływ formy pytania na jakość odpowiedzi) i Q7 (skłonność do modyfikacji zapytań) miały istotne znaczenie w rozróżnieniu klastrów. Niski poziom wariancji w obrębie klastrów dla pytania nr 3 sugeruje, iż użytkownicy w każdej grupie korzystają z AI w zbliżony sposób. Natomiast pytanie nr 7 wykazało największe rozbieżności wśród ankietowanych. Użytkownicy mieli odmienne zdanie na temat zmiany zapytań, gdy odpowiedzi są niesatysfakcjonujące.

Na podstawie rozkładu liczebności klastrów wykazano, że klaster 0 jest najliczniejszy i stosunkowo spójny, charakteryzuje się umiarkowanym zaangażowaniem w interakcję z AI. Natomiast klaster 2 jest bardziej zróżnicowany, co wynika z wysokiego poziomu wiedzy i specyficznych oczekiwań wobec systemu.

Charakter zapytań użytkowników i ich kontekst miały istotny wpływ na wyniki klasteryzacji. Użytkownicy z klastra 1, którzy korzystają z AI intensywnie, zadawali najczęściej ogólne pytania o prostej strukturze, co spowodowało mniejszą potrzebę modyfikacji zapytań. W klastrze nr 2, w którym dominowały bardziej specjalistyczne i techniczne zapytania, użytkownicy wykazywali większą skłonność do zmiany treści pytań w przypadku niesatysfakcjonujących odpowiedzi AI. Klaster 0 natomiast łączył użytkowników, których zapytania były umiarkowanie szczegółowe, a kontekst obejmował zarówno codzienne zadania, jak i bardziej złożone scenariusze.

Treści zadań lub poleceń wprowadzanych do modeli AI również miały wpływ na postrzeganą jakość odpowiedzi. Użytkownicy, którzy formułowali bardziej precyzyjne pytania, wykazywali większą satysfakcję z odpowiedzi generowanych przez system, co szczególnie wyróżniało użytkowników klastra 0. W tym klastrze zwracano uwagę zarówno na formę pytania, jak i na kontekst, co wpłynęło na wyższą świadomość jakości uzyskiwanych odpowiedzi. Natomiast użytkownicy klastra 2 byli bardziej krytyczni wobec wyników i wykazywali najwyższą skłonność do modyfikowania pytań, dostosowując je do swoich potrzeb.

Podsumowując, zarówno analizę odpowiedzi ankietowanych i wyników klasteryzacji, wykazano istotne różnice w sposobach korzystania z narzędzi AI. Uczestnicy dostrzegają znaczenie wpływu kontekstu oraz formy pytania na jakość generowanych odpowiedzi i chętnie dostosowują swoje zapytania w celu uzyskania lepszych rezultatów. Obserwacje te potwierdzają znaczenie umiejętnego formułowania zapytań jako kluczowego elementu efektywnego korzystania z narzędzi opartych na sztucznej inteligencji.

6.2. Szczegółowa analiza porównawcza odpowiedzi uzyskanych od modeli AI

W ramach analizy porównawczej oceniono odpowiedzi generowane przez różne modele sztucznej inteligencji, w tym GPT-4.5, DeepSeek, Gemini oraz inne, na ustandaryzowany zbiór pytań z różnych kategorii tematycznych. Celem badania było nie tylko określenie ogólnej jakości odpowiedzi, ale również identyfikacja charakterystycznych cech językowych i merytorycznych, które wpływają na ich użyteczność i trafność.

Porównanie wykazało wyraźne różnice pomiędzy modelami pod względem treści, jak i formy odpowiedzi. Model GPT-4.5 konsekwentnie prezentował wysoki poziom poprawności gramatycznej, stylistycznej oraz spójności logicznej, co potwierdziły wyniki

uzyskane we wszystkich metrykach. Odpowiedzi tego modelu charakteryzowały się specjalistycznymi określeniami bez nadmiernego upraszczania treści i wykazywały wysoki poziom trafności odpowiedzi względem treści pytania. Modele takie jak PLLuM czy o3 używały sformułowań ogólnych, a nawet potocznych, co obniżało poziom wypowiedzi.

W przypadku modelu Gemini, zaobserwowano, że jego odpowiedzi były zdecydowanie najdłuższe spośród wszystkich testowanych modeli. Mimo obszernej formy, model ten osiągnął relatywnie niskie wyniki w metrykach BLEU i ROUGE, co może świadczyć o słabszym dopasowaniu słownictwa do oczekiwanego wzorca i niższej precyzji. Wyniki BERTScore również były niższe niż w przypadku modeli takich jak GPT-4.5 czy Copilot, co wskazuje na ograniczoną zgodność semantyczną i tylko częściowe odwołanie do kontekstu pytania.

Z kolei odpowiedzi generowane przez DeepSeek charakteryzowały się również długością, często przekraczającą 200 słów. Ich jakość oceniona za pomocą metryk ROUGE i BERTScore była umiarkowana, lecz lepsza niż Gemini, ale wyraźnie niższa niż GPT-4.5. To sugeruje, że model ten często rozbudowuje odpowiedzi, wprowadzając dodatkowy kontekst, ale nie zawsze trafnie oddaje sedno pytania. W odpowiedzi na pytanie „Co to jest fotosynteza?”, DeepSeek wygenerował wielozdaniowy opis z wyjaśnieniem reakcji chemicznych oraz roli chlorofilu, co wskazuje na tendencję do tworzenia szczegółowych, technicznych wyjaśnień.

Natomiast modele GPT-4.5 i Copilot (GPT-4 Turbo) wykazywały większą zdolność do systematyzowania treści m.in. ich odpowiedzi były krótsze, bardziej zwarte, logiczne i jednocześnie merytorycznie kompletne. GPT-4.5 uzyskał najwyższe wyniki dla BLEU, ROUGE oraz BERTScore, co czyni go najbardziej spójnym modelem spośród porównywanych. Copilot z kolei prezentuje zbliżony poziom zgodności znaczeniowej, co czyni go solidną alternatywą.

Analiza długości i liczby unikalnych tokenów ujawniła, że bardziej rozbudowane odpowiedzi niekoniecznie były lepsze jakościowo. Niektóre modele generowały długie wypowiedzi o wysokim nasyceniu słownictwem, jednak nie zawsze przekładało się to na wyższą ocenę jej zgodności znaczeniowej.

Warto zwrócić uwagę, iż niektóre modele konstruowały odpowiedzi w formie punktów, inne jako spójną narrację, choć we wszystkich zapytaniach było wskazane, że odpowiedzi mają być spójną narracją. Modele takie jak GPT-4.5 cechowały się wyższym poziomem adaptacji do kontekstu, dzięki temu potrafiły lepiej dopasować styl wypowiedzi do charakteru pytania. W przypadku pytań definicyjnych w tych modelach generowane odpowiedzi były krótkie i zwarte, natomiast na pytania analityczne generowane odpowiedzi były bardziej rozbudowane.

Zauważalna była również zależność pomiędzy kategorią pytania, a skutecznością modelu w generowaniu odpowiedzi. Pytania z kategorii „wiedza ogólna” były zazwyczaj poprawnie generowane przez większość modeli. Natomiast pytania o wyższym poziomie złożoności, zwłaszcza z zakresu programowania lub nauk ścisłych, wymagały większego zrozumienia kontekstu, co skutkowało spadkiem jakości odpowiedzi w przypadku słabszych modeli.

Spójność logiczna i struktura argumentacji były istotnym aspektem jakości. Modele bardziej zaawansowane stosowały strukturę wypowiedzi z wprowadzeniem, rozwinięciem i podsumowaniem. Przykładowo w odpowiedzi na pytanie „Jakie były główne przyczyny wybuchu II wojny światowej?”, GPT-4.5 najpierw przedstawił tło historyczne, następnie

wymienił czynniki polityczne i gospodarcze, a na koniec podsumował znaczenie tych wydarzeń. W przeciwieństwie do tego, model o4-mini często ograniczał się do listy punktów bez wyraźnej logiki narracji.

Odpowiedzi analizowano również pod kątem zdolności modeli do uchwycenia kontekstu pytania. GPT-4.5 i DeepSeek potrafiły dostosowywać styl i zakres odpowiedzi do poziomu szczegółowości pytania, podczas gdy słabsze modele, jak PLLuM, często ograniczały się do prostych opisów.

Zidentyfikowano również typowe błędy w odpowiedziach słabszych modeli m.in. nieprecyzyjne tłumaczenia terminów, pomijanie istotnych wątków w pytaniach przyczynowo skutkowych, a także pojawianie się powtórzeń. Szczególnie często pojawiały się one w odpowiedziach modelu DeepSeek i o4-mini. Czasami pojawiały się też niepotwierdzone fakty, co wskazuje na ostrożne wykorzystywanie modeli.

Podsumowując, szczegółowa analiza odpowiedzi różnych modeli językowych wykazała, że jakość generowanego tekstu zależy nie tylko od długości wypowiedzi, ale przede wszystkim od zdolności modelu do logicznego myślenia, zachowania spójności i precyzyjnego odwzorowania kontekstu pytania. Modele wyższej generacji, takie jak GPT-4.5 potrafią generować treści nie tylko poprawne merytorycznie, ale również dostosowane do oczekiwań użytkowników pod względem formy, tonu i stylu wypowiedzi. Różnice między modelami wykazują, że ich dobór powinien być uzależniony od konkretnego zastosowania.

6.3. Czynniki mające największy wpływ na różnice między odpowiedziami

Na podstawie przeprowadzonej analizy porównawczej oraz interpretacji wyników ankiety i klasteryzacji, możliwe było wyodrębnienie kilku kluczowych czynników, które w sposób istotny wpływają na różnice pomiędzy odpowiedziami generowanymi przez modele generatywne. Zarówno charakter zapytań, jak i budowa oraz sposób działania modelu, determinują poziom użyteczności i zadowolenia użytkownika z uzyskanego rezultatu. Na różnice między generowanymi odpowiedziami wpływają przede wszystkim następujące czynniki:

- Stopień precyzji zapytania i obecność kontekstu

Najsilniejszym czynnikiem wprowadzającym różnice w jakości odpowiedzi jest forma pytania, a szczególnie jego precyzja oraz zawarty kontekst. Pytania sformułowane w sposób ogólny, bez jakichkolwiek wskazówek, skutkowały odpowiedziami bardziej powierzchownymi, niezależnie od użytego modelu. Natomiast w przypadku pytań, które zawierają szczegółowe informacje, słowa kluczowe lub konkretnie określone oczekiwania, generowały odpowiedzi bardziej uporządkowane i merytoryczne. Dane z ankiety potwierdzają, iż użytkownicy dostrzegają, że modyfikacja pytania lub dodanie szczegółów prowadzi do zmiany wygenerowanej odpowiedzi.

- Zdolność modelu do rozumienia znaczenia pytania

Drugim istotnym czynnikiem jest architektura modelu i jego zdolność do interpretacji zapytania. Analiza porównawcza wykazała, że niektóre modele lepiej radzą sobie z rozpoznawaniem intencji użytkownika, a także z dostosowywaniem długości i stylu wypowiedzi do charakteru pytania. Natomiast inne generują odpowiedzi fragmentaryczne i uproszczone, co potwierdzają wyniki takie jak BLEU, BERTScore oraz ROUGE.

- Rodzaj i tematyka pytania

Istotną rolę odgrywa również dziedzina wiedzy, której dotyczy pytanie. W pytaniach z zakresu wiedzy ogólnej większość modeli generowała odpowiedzi zadowalające. Natomiast przy tematach specjalistycznych widoczna była wyraźna dysproporcja w jakości odpowiedzi między modelami.

- Zachowania użytkowników i ich poziom zaawansowania

Analiza klastrów użytkowników, pokazała, że osoby bardziej zaawansowane w korzystaniu z narzędzi AI formułowały pytania techniczne, często z rozbudowanym kontekstem, co prowadziło do uzyskania odpowiedzi bardziej złożonych, ale także bardziej narażonych na błędy w przypadku słabszych modeli. Natomiast inni użytkownicy zadawali pytania ogólne i nie modyfikowali ich zbyt często, co ograniczało jakość wyników.

- Metody oceny odpowiedzi i kryteria użytkowników

Wyniki ankiety ujawniły również, że użytkownicy posługują się różnymi kryteriami oceny jakości odpowiedzi. Niektórzy skupiają się na długości i szczegółowości, natomiast inni na przekazie informacji. Te subiektywne oczekiwania wpływają na to, jak dana odpowiedź jest oceniana i odbierana.

Zróżnicowanie odpowiedzi generowanych przez modele AI wynika z kombinacji kilku czynników m.in. konstrukcji pytania, możliwości modelu, tematyki oraz poziomu kompetencji użytkownika. Największy wpływ na jakość odpowiedzi miało umiejętne formułowanie zapytań oraz zdolność modelu do uchwycenia intencji użytkownika. Niektóre modele okazały się bardziej elastyczne i lepiej przystosowane do obsługi złożonych zapytań. Jednocześnie, skuteczność interakcji zależy także od użytkownika m.in. jego wiedzy, doświadczenia oraz gotowości do modyfikowania zapytań w odpowiedzi na jakość otrzymanych treści.

7. Interpretacja wyników badań

Rozdział ten poświęcony jest podsumowaniu i interpretacji uzyskanych wyników empirycznych, odnosząc je do postawionych wcześniej hipotez badawczych. Celem tego etapu jest ocena stopnia, w jakim zgromadzone dane potwierdzają lub negują przyjęte założenia teoretyczne. W dalszej części rozdziału poddano analizie potencjalne ograniczenia, które mogły mieć wpływ na przebieg oraz rezultaty badań. Natomiast końcowa część zawiera rekomendacje praktyczne wynikające z przeprowadzonych analiz, a także wskazania możliwych kierunków przyszłych badań, które mogłyby pogłębić poruszaną problematykę.

7.1. Ocena zgodności wyników badań z przyjętymi hipotezami

Analiza wyników potwierdza, że przyjęte hipotezy badawcze znajdują w większości przypadków potwierdzenie w uzyskanych wynikach. Pierwsza z hipotez, zakładająca możliwość wyodrębnienia spójnych grup użytkowników na podstawie stylu i tematyki zapytań, została zweryfikowana pozytywnie. Dzięki wykorzystaniu metody klasteryzacji KMeans udało się wyróżnić trzy wyraźne klastry użytkowników, zróżnicowane pod względem częstotliwości korzystania z AI, poziomu modyfikacji zapytań oraz ich złożoności. Użytkownicy z klastra 2 cechowali się bardziej zaawansowanym podejściem do formułowania zapytań, co przekładało się na bardziej analityczne i szczegółowe odpowiedzi. Z kolei klaster 1 reprezentował użytkowników poszukujących szybkich, prostych

odpowiedzi bez doprecyzowania kontekstu, co skutkowało obniżeniem jakości i krótszymi odpowiedziami bez zawartych szczegółów.

Druga hipoteza, dotycząca związku pomiędzy motywacją użytkowników, a formą odpowiedzi generowanej przez AI, również została potwierdzona. Użytkownicy formułujący pytania z jasno określonym celem, wzbogacane kontekstem lub dodatkowymi informacjami, otrzymywali bardziej rozbudowane odpowiedzi. Osoby z klastra 0 i 2, które częściej modyfikowały swoje zapytania, przez co uzyskiwały wypowiedzi bogatsze w szczegóły, natomiast w klastrze 1, w którym czas na odpowiedź był istotny, odpowiedzi były bardziej ogólne i skrócone.

Hipoteza odnośnie istnienia węzłów centralnych w sieci podobieństwa użytkowników również została potwierdzona, ze względu na wyodrębnione węzły o wysokim stopniu centralności, które łączyły cechy charakterystyczne dla różnych klastrów. Centralni użytkownicy tworzyli uniwersalne wzorce zapytań, wykazując elastyczność w stylu, tematyce i celu zapytań, co może wskazywać na ich szczególną rolę w modelowaniu typowych zachowań użytkowników narzędzi AI.

Kolejne hipotezy dotyczyły wpływu formy zapytania oraz obecności kontekstu na jakość odpowiedzi. Dane zebrane w badaniu z wykorzystaniem ankiet oraz eksperymentalnym w pełni potwierdziły te założenia. Zarówno deklaracje uczestników, jak i analiza jakości odpowiedzi AI wykazały, iż dokładność i trafność generowanych treści znacząco rosną, gdy zapytania są formułowane precyzyjnie i zawierają istotne informacje na temat kontekstu. W przypadku ankietowanych wskazywano wpływ na poprawę jakości odpowiedzi poprzez zmianę formy pytania, a także modyfikacje pytań tylko w przypadku braku satysfakcjonującej odpowiedzi.

Ostatecznie analiza porównawcza odpowiedzi generowanych przez modele AI wykazała, że nawet przy tej samej treści pytania, różnice w długości, stylu i strukturze odpowiedzi są znaczące. Modele bardziej zaawansowane, jak GPT-4.5, lepiej adaptują się do formy pytania i kontekstu, co pozwala uznać hipotezę o kluczowej roli formy zapytań na generowane treści za zasadną.

Przeprowadzone badania empiryczne w znacznej mierze potwierdziły założone hipotezy. Wyniki wskazują, że sposób w jaki użytkownicy formułują pytania, ich intencje, kontekst oraz poziom wiedzy mają istotny wpływ na jakość odpowiedzi. Równocześnie, analiza wykazała obecność spójnych wzorców zachowań użytkowników oraz mechanizmów decydujących o skuteczności interakcji z modelami językowymi.

7.2. Omówienie ograniczeń przeprowadzonych badań

Pomimo uzyskanych wyników, należy mieć świadomość pewnych ograniczeń towarzyszących przeprowadzanemu badaniu, które mogą wpływać na interpretację rezultatów.

Liczebność próby badawczej wynosiła 80 uczestników, choć była to wartość wystarczająca do przeprowadzenia analizy klasteryzacji i wnioskowania statystycznego, nie pozwala na pełne uogólnienie wyników na całą populację użytkowników narzędzi AI. Struktura próby, choć zróżnicowana pod względem wieku i płci, wciąż mogła być nie w pełni reprezentatywna, zwłaszcza jeśli chodzi o poziom zaawansowania technicznego lub specyfikę zastosowań AI w codziennym życiu.

Zastosowana metodologia również mogła być pewnym ograniczeniem, ponieważ opierała się w znacznej mierze na deklaracyjnych danych uzyskanych w badaniu z wykorzystaniem ankiet. Choć ankieta uwzględniała pytania dotyczące rzeczywistych praktyk użytkowników, istnieje ryzyko zniekształceń wynikających z subiektywności odpowiedzi, czy efektu oczekiwania społecznych.

Kolejnym ograniczeniem jest złożoność samego procesu formułowania zapytań. Badanie opierało się na analizie stylu, długości, kontekstu i celu zapytań, jednak nie uwzględniało wszystkich możliwych aspektów językowych i pragmatycznych, takich jak ton wypowiedzi, użyte słownictwo, czy emocjonalne nacechowanie treści. Czynniki te mogą również wpływać na jakość i formę odpowiedzi generowanych przez modele sztucznej inteligencji.

W przypadku porównawczej analizy modeli językowych istotnym ograniczeniem było wykorzystanie tylko wybranych pytań z ustandaryzowanego zestawu. Pytania obejmowały różne kategorie tematyczne, zakres badań nie był wystarczająco szeroki, aby móc wyciągnąć wnioski dotyczące skuteczności modeli w bardzo wąskich, specjalistycznych dziedzinach. Dodatkowo, zastosowane metryki oceny jakości mają pewne ograniczenia i nie w pełni oddają subiektywną użyteczność odpowiedzi dla konkretnego użytkownika.

Warto także zaznaczyć, że dynamika rozwoju technologii AI sprawia, iż wyniki uzyskane w momencie badania mogą szybko tracić aktualność ze względu na stale aktualizowane i rozwijane modele językowe, co może wpłynąć na ich skuteczność.

Przedstawione ograniczenia nie podważają zasadności i wartości uzyskanych wyników, lecz wskazują na konieczność ostrożności przy interpretacji oraz potrzebę dalszych badań w szerszym zakresie użytkowania narzędzi opartych na sztucznej inteligencji.

7.3. Rekomendacje praktyczne oraz możliwości dalszych badań

Na podstawie przeprowadzonych badań można sformułować szereg rekomendacji, które mogą przyczynić się do bardziej efektywnego wykorzystania modeli językowych przez użytkowników końcowych. Szczególną uwagę warto zwrócić na sposób formułowania zapytań przez użytkowników, ponieważ to właśnie ich struktura, precyzja i kontekst w największym stopniu wpływają na jakość oraz przydatność otrzymanych odpowiedzi. Analiza interakcji pokazała, że poprawa jakości komunikacji z modelem możliwa jest poprzez świadome projektowanie treści wejściowych, dlatego warto postulować o upowszechnianie wiedzy na temat inżynierii promptów.

Zapytania powinny być jednoznaczne i pozbawione niejasnych sformułowań, które mogłyby prowadzić do zniekształcenia intencji użytkownika. Modele bazujące na przewidywaniu kolejnych słów na podstawie wzorców językowych, są szczególnie podatne na niejednoznaczność, co może skutkować generowaniem treści, które odbiegają od zamierzonego celu.

Równie istotna okazuje się spójność zapytań, czyli utrzymanie jednolitego stylu, tonu oraz zakresu tematycznego w obrębie jednego zapytania. Zmienność stylistyczna w ramach jednego zapytania może prowadzić do odpowiedzi nieadekwatnych lub zbyt ogólnych. Zachowanie spójności ułatwia modelowi zrozumienie struktury zdania i zmniejsza ryzyko wygenerowania zbędnych lub błędnych treści.

Kolejny istotny aspekt dotyczy celu zapytania, czyli umiejętnego określenia, co dokładnie ma zostać osiągnięte za pomocą danej interakcji. W przypadku braku wyraźnie określonego celu model może przyjąć niewłaściwe założenia i wygenerować treść, która jest

poprawna językowo, ale nie spełnia oczekiwań użytkownika. Precyzyjne wskazanie pozwala uzyskać bardziej trafną i użyteczną odpowiedź.

Kwestia niezmienności treści również odgrywa istotną rolę. W wielu przypadkach użytkownik oczekuje, że model dokona jedynie ograniczonej ingerencji w wybrany fragment tekstu, pozostawiając pozostałą część bez zmian. Niestety, obecnie wiele modeli generuje odpowiedź na nowo, co może skutkować przepisywaniem całego dokumentu, nawet jeśli potrzebna jest jedynie kilka małych zmian. Taki sposób może być nieefektywny zwłaszcza w pracy z dłuższymi dokumentami, które wymagają zachowania oryginalnej struktury i stylu.

W związku z powyższym, interesującym kierunkiem dalszych badań jest rozwój technik punktowej edycji treści. Celem tego podejścia jest umożliwienie modelom językowym identyfikowania i modyfikowania jedynie tych fragmentów tekstu, które rzeczywiście tego wymagają, bez ingerencji w pozostałe części. Prace nad tego rodzaju funkcjonalnością już trwają, między innymi w postaci promptów różnicowych, modeli specjalnie wyuczonych edycji, czy zastosowanie znaczników wskazujących miejsce zmiany. Wprowadzenie takich mechanizmów mogłoby zwiększyć użyteczność modeli AI w zadaniach związanych z redagowaniem tekstu, zwłaszcza w sytuacjach wymagających dostosowania do odbiorcy.

W tym kontekście warto również zwrócić uwagę na nową koncepcję, która pojawia się w środowisku dużych modeli językowych tzw. Model Context Protocol (MCP). Celem MCP jest ustandaryzowanie sposobu, w jaki użytkownicy przekazują informacje do modelu, co umożliwi im dostęp do różnych danych i narzędzi. Protokół ten zakłada, że oprócz właściwej treści zapytania do modelu powinny być dostarczane metadane, takie jak intencja użytkownika, zakres dopuszczalnych zmian, wyraźne oznaczenia miejsc edycji oraz informacje o oczekiwanym formacie odpowiedzi. Wprowadzenie takich zmian skutkowałoby podniesieniem przewidywalności i powtarzalności generowanych odpowiedzi. Istotnym faktem jest możliwość rozszerzenia MCP o elementy pozwalające na dostosowanie wyboru modelu do preferencji użytkownika, co mogłoby stanowić kluczowy krok w kierunku bardziej spersonalizowanej i świadomej interakcji z modelami językowymi.

Technika punktowej edycji oraz koncepcja MCP nie zostały bezpośrednio uwzględnione w przeprowadzonych badaniach. Decyzja ta wynikała z faktu, że obie metody znajdują się nadal na etapie rozwoju i braku szerokiego zastosowania w praktyce. Ich skuteczność i integracja z obecnymi systemami AI wciąż wymaga dalszych badań, jednak w przyszłości mogą odegrać istotną rolę w tworzeniu precyzyjnych i adaptacyjnych rozwiązań.

Rozszerzenie pracy o potencjalne kierunki rozwoju oraz zastosowania wyników badań w kontekście grup docelowych użytkowników pozwala wskazać obszary wymagające dalszej eksploracji. Wśród nich warto wyróżnić: rozwój narzędzi wspierających selekcję modeli oraz formułowanie zapytań w zależności od charakterystyki użytkownika. Istotnym kierunkiem jest również optymalizacja modeli generatywnych z uwzględnieniem specyfiki różnych grup odbiorców. Kolejnym obszarem rozwoju może być projektowanie nowych rodzajów rankingów modeli językowych (tzw. leaderboardów), które uwzględniają zarówno cechy użytkowników, jak i konkretne scenariusze zastosowań. Takie podejście może przyczynić się do bardziej dopasowanego, efektywnego i odpowiedzialnego wykorzystania technologii generatywnych w różnych kontekstach społecznych i zawodowych.

Przedstawione rekomendacje oraz zaproponowane kierunki rozwoju wynikają bezpośrednio z obserwacji zgromadzonych podczas badań i analiz. Zwiększenie precyzji lub spójności zapytań nie tylko poprawia jakość odpowiedzi, ale także umożliwia stosowanie

bardziej zaawansowanych i kontrolowanych interakcji z tymi narzędziami. Rozwój technik lokalnej edycji oraz koncepcji MCP może w przyszłości stanowić ważny etap w kierunku dalszego rozwoju sztucznej inteligencji.

8. Podsumowanie

Celem niniejszej pracy było zbadanie, w jaki sposób forma i kontekst zapytań kierowanych do systemów sztucznej inteligencji wpływają na jakość oraz użyteczność generowanych odpowiedzi. Badania łączyły analizę empiryczną, ocenę wyników ankiet oraz eksperymenty z wykorzystaniem różnych modeli językowych.

Praca ta skierowana jest przede wszystkim do osób, które chcą lepiej zrozumieć działanie narzędzi opartych na sztucznej inteligencji, poznać różnice pomiędzy modelami językowymi oraz nauczyć się formułowania skutecznych zapytań. Może być ona przydatna zarówno dla początkujących użytkowników, jak i dla tych, którzy chcą zwiększyć efektywność interakcji z AI. Zgromadzone wnioski i obserwacje mają charakter praktyczny i mogą służyć jako przewodnik w świadomym korzystaniu z nowoczesnych systemów językowych.

Otrzymane wyniki dostarczyły solidnych podstaw do sformułowania praktycznych wniosków na temat zasad formułowania zapytań. Praca pozwoliła także wskazać konkretne kierunki dalszych badań nad optymalizacją wykorzystania modeli w różnych zastosowaniach.

8.1. Podsumowanie zrealizowanych badań

Badania empiryczne zostały przeprowadzone na dwa sposoby: poprzez analizę generowanych odpowiedzi oraz za pomocą ankiety. W eksperymencie oceniano odpowiedzi modeli takich jak GPT-4.5, Gemini, DeepSeek czy Copilot, zwracając uwagę na jakość, spójność i trafność odpowiedzi.

Z kolei ankieta przeprowadzona wśród 80 uczestników pozwoliła zidentyfikować różnice w sposobie korzystania z AI, z uwzględnieniem poziomu zaawansowania technicznego, częstotliwości modyfikowania zapytań i świadomości wpływu kontekstu na odpowiedzi. Większość respondentów przyznała, że zmiana formy pytania oraz doprecyzowanie kontekstu znacząco wpływa na jakość odpowiedzi generowanej przez AI. Wskazano również na częstą praktykę modyfikowania pytań w przypadku otrzymania niezadowolających rezultatów.

Wykorzystanie klasteryzacji umożliwiło wyróżnienie trzech grup użytkowników zróżnicowanych pod względem korzystania z AI. Klaster 0 to użytkownicy umiarkowanie zaangażowani, klaster 1 – początkujący, korzystający z AI przy prostych zadaniach, a klaster 2 – zaawansowani, zadający techniczne i złożone pytania. Grupy te różniły się pod względem modyfikowania zapytań, oczekiwań wobec odpowiedzi.

Analiza porównawcza odpowiedzi wygenerowanych przez różne modele AI wykazała istotne różnice w jakości, stylu i strukturze wypowiedzi. Modele takie jak GPT-4.5 wyróżniały się wysoką precyzją, umiejętnością adaptacji oraz spójnością wypowiedzi. Natomiast modele takie jak Gemini czy PLLuM częściej generowały odpowiedzi zbyt ogólne lub niespójne, mimo długości generowanych treści.

8.2. Wnioski końcowe z przeprowadzonych analiz

Na podstawie zebranych danych i przeprowadzonych analiz można sformułować kilka kluczowych wniosków:

- Forma i kontekst zapytań są kluczowe dla jakości odpowiedzi AI. Modele radzą sobie znacznie lepiej, gdy pytania są konkretne, zawierają dodatkowe informacje i jasno określone oczekiwania. Brak precyzji skutkuje odpowiedziami ogólnymi, niezależnie od jakości modelu.
- Użytkownicy mają realny wpływ na jakość interakcji z AI. Osoby modyfikujące pytania i świadomie dopasowujące je do celu otrzymują odpowiedzi bardziej adekwatne. Częste poprawianie treści zapytań okazuje się ważnym elementem skutecznej komunikacji z modelem.
- Różnice między modelami językowymi są zauważalne. Nie wszystkie modele potrafią odpowiednio przetwarzać pytania o wyższym poziomie trudności. Zaawansowane modele lepiej rozumieją kontekst i intencje użytkownika, generując bardziej wartościowe odpowiedzi np. GPT-4.5.
- Styl korzystania z AI zależy od poziomu zaawansowania użytkownika. Zaawansowani użytkownicy są bardziej krytyczni wobec odpowiedzi, częściej modyfikują zapytania i oczekują większej precyzji. Osoby początkujące częściej akceptują odpowiedzi ogólne i rzadziej wprowadzają poprawki.
- Ocena odpowiedzi AI jest subiektywna i zróżnicowana. Użytkownicy kierują się różnymi kryteriami m.in. jedni preferują zwięzłość i przejrzystość, inni poszukują szczegółowości i głębi argumentacji, co sugeruje, że projektowanie narzędzi sztucznej inteligencji powinno uwzględniać różne potrzeby i style użytkowników.
- Długość odpowiedzi nie zawsze koreluje z jej jakością. Modele generujące długie wypowiedzi niekoniecznie dostarczają bardziej trafnych informacji. Ważniejsza okazuje się spójność, adekwatność i precyzja względem treści zapytania.
- Dobór odpowiedniego modelu AI powinien być dostosowany do charakteru zadania. W zastosowaniach technicznych i analitycznych zalecane są modele o wysokiej zdolności adaptacji, natomiast w codziennych zadaniach prostsze i szybsze rozwiązania mogą być wystarczające.

Skuteczność wykorzystania narzędzi AI to rezultat współdziałania technologii i użytkownika. Umiejętne formułowanie zapytań, dostosowanie kontekstu oraz świadome korzystanie z możliwości modelu mają kluczowe znaczenie dla uzyskania trafnych i przydatnych odpowiedzi. Dotyczy to również innych narzędzi, służących do generowania obrazów i animacji, gdzie jakość rezultatów równie silnie zależy od precyzji zapytań. Praca ta poza aspektem teoretycznym, ma również wymiar praktyczny – może posłużyć jako pomoc dla osób pragnących nie tylko zgłębić wiedzę na temat zasady działania systemów AI, lecz także opanować umiejętność zadawania pytań w sposób sprzyjający uzyskaniu bardziej trafnych i użytecznych odpowiedzi.

Bibliografia

- [1] Y. Jiang, X. Li i H. Luo, „Quo vadis artificial intelligence?,” *Discover Artificial Intelligence*, 2022.
- [2] M. Haenlein i A. Kaplan, „A Brief History of Artificial Intelligence: On the Past, Present, and Future of Artificial Intelligence,” *California Management Review*, 2019.
- [3] V. Alto, Generatywna sztuczna inteligencja z ChatGPT i modelami OpenAI. Podnieś swoją produktywność i innowacyjność za pomocą GPT3 i GPT4, Helion, 2024.
- [4] J. Flemings, W. Zhang, B. Jiang, Z. Takhirov i M. Annavaram, „CHARACTERIZING CONTEXT INFLUENCE AND HALLUCINATION IN SUMMARIZATION,” *International Conference on Learning Representations*, 2025.
- [5] P. J. Rousseeuw, „Silhouettes: A graphical aid to the interpretation and validation of cluster analysis,” *Journal of Computational and Applied Mathematics*, pp. 53-65, 1987.
- [6] T. Calinski i J. Harabasz, „A dendrite method for cluster analysis,” *Communications in Statistics*, pp. 1-27, 1974.
- [7] D. L. i B. D. Davies, „A Cluster Separation Measure,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, pp. 224-227, 1979.
- [8] F. Morandín-Ahuerma, „What is Artificial Intelligence?,” *International Journal of Research Publication and Reviews*, tom 3, nr 12, p. 1947–1951, 2022.
- [9] E. A. Płocha, „O pojęciu sztucznej inteligencji i możliwościach jej zastosowania w postępowaniu cywilnym,” *Prawo w Działaniu. Sprawy Cywilne*, tom 44, p. 273–291, 2020.
- [10] High-Level Expert Group on AI, „A Definition of AI: Main Capabilities and Disciplines,” Bruksela, 2019.
- [11] P. Wang, „On Defining Artificial Intelligence,” *Journal of Artificial General Intelligence*, tom 10, nr 2, p. 1–37, 2019.
- [12] D. Dobrev, „A Definition of Artificial Intelligence,” 2012. <https://arxiv.org/abs/1210.1568>.
- [13] I. Goodfellow, Y. Bengio i A. Courville, *Deep Learning*, MIT Press, 2016.
- [14] M. A. Nielsen, *Neural Networks and Deep Learning*, Determination Press, 2015.
- [15] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser i I. Polosukhin, „Attention Is All You Need,” 2017.
- [16] MIT OpenCourseWare, „Introduction to Machine Learning (6.036),” 2020. <https://ocw.mit.edu/courses/6-036-introduction-to-machine-learning-fall-2020/>.
- [17] R. S. Sutton i A. G. Barto, *Reinforcement Learning: An Introduction*, 2 red., 2018.
- [18] Y. LeCun, Y. Bengio i G. Hinton, „Deep Learning,” *Nature*, tom 521, nr 7553, p. 436–444, 2015.
- [19] P. Boutot, M. R. Tabassum, A. Abedin i S. Mustafiz, „Requirements Development for IoT Systems with UCM4IoT,” 2022.

- [20] D. Jurafsky i J. H. Martin, *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition with Language Models*, 2025.
- [21] R. Navigli, „Natural Language Understanding: Instructions for (Present and Future) Use,” w *Proceedings of the Twenty-Seventh International Joint Conference on Artificial Intelligence (IJCAI-18)*, 2018.
- [22] B. Li, Y. Hou i W. Che, „Data augmentation approaches in natural language processing: A survey,” *AI Open*, tom 3, p. 71–90, 2022.
- [23] K. S. Jones, „Natural Language Processing: A Historical Review,” w *Current Issues in Computational Linguistics: In Honour of Don Walker*, Springer Netherlands, 1994, p. 3–16.
- [24] P. Johri, S. K. Khatri, A. Al-Taani, M. Sabharwal, S. Suvanov i A. Chauhan, „Natural Language Processing: History, Evolution, Application, and Future Work,” w *Applications of Artificial Intelligence in Engineering*, Springer, 2021, p. 365–375.
- [25] J. Devlin, M.-W. Chang, K. Lee i K. Toutanova, „BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding,” 2019.
- [26] M. Honnibal, I. Montani, S. Van Landeghem i A. Boyd, „spaCy: Industrial-strength Natural Language Processing in Python,” 2020.
- [27] T. Wolf, L. Debut, V. Sanh, J. Chaumond, C. Delangue i A. Moi, „Transformers: State-of-the-Art Natural Language Processing,” *Association for Computational Linguistics*, pp. 38-45, 2020.
- [28] „PLLuM (Polish Large Language Model),” 2025. <https://pllum.org.pl/#about>.
- [29] DeepSeek-AI, „DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via,” 2025. https://github.com/deepseek-ai/DeepSeek-R1/blob/main/DeepSeek_R1.pdf.
- [30] DeepSeek-AI, „DeepSeek-V3 Technical Report,” 2025. <https://arxiv.org/pdf/2412.19437>.
- [31] Qwen Team, Alibaba Group, „Qwen Technical Report,” 2023. <https://arxiv.org/pdf/2309.16609>.
- [32] Google AI for Developers, „Gemini models | Gemini API documentation,” Google, 2025. <https://ai.google.dev/gemini-api/docs/models>.
- [33] Google DeepMind, „Gemini 2.5 Pro,” Google DeepMind, 2025. <https://deepmind.google/technologies/gemini/pro>.
- [34] Microsoft, „Architecture diagrams of licensed Microsoft 365 data protection, oversharing, and auditing features that affect Microsoft 365 Copilot,” Microsoft, 2025. <https://learn.microsoft.com/en-us/copilot/microsoft-365/microsoft-365-copilot-architecture-data-protection-auditing>.
- [35] Microsoft, „Microsoft 365 Copilot architecture and how it works,” Microsoft, 2025. <https://learn.microsoft.com/en-us/copilot/microsoft-365/microsoft-365-copilot-architecture>.
- [36] Microsoft, „Microsoft 365 Copilot overview,” Microsoft, 2025. <https://learn.microsoft.com/en-us/copilot/microsoft-365/microsoft-365-copilot-overview>.
- [37] OpenAI, „Introducing GPT-4.5,” 2025. <https://openai.com/index/introducing-gpt-4-5/>.

- [38] OpenAI, „GPT-4.5 System Card,” 2025. <https://openai.com/index/gpt-4-5-system-card/>.
- [39] OpenAI, „GPT-4o System Card,” 2024. <https://arxiv.org/abs/2410.21276>.
- [40] OpenAI, „Introducing OpenAI o3 and o4-mini,” 2025. <https://openai.com/index/introducing-o3-and-o4-mini/>.
- [41] H. Touvron, L. Martin, K. Stone, P. Albert, A. Almahairi, Y. Babaei i e. al., „Llama 2: Open Foundation and Fine-Tuned Chat Models,” 2023.
- [42] K. Kavukcuoglu, „Gemini 2.5: Our most intelligent AI model,” Google, 2025. <https://blog.google/technology/google-deepmind/gemini-model-thinking-updates-march-2025/>.
- [43] S. Pichai, D. Hassabis i K. Kavukcuoglu, „Introducing Gemini 2.0: our new AI model for the agentic era,” Google, 2024. <https://blog.google/technology/google-deepmind/google-gemini-ai-update-december-2024/>.
- [44] P. Kane, „Access the latest 2.0 experimental models in the Gemini app.,” Google, 2025. <https://blog.google/feed/gemini-app-experimental-models/>.
- [45] K. Kampf, „Create and edit images with Gemini 2.0 in preview,” Google, 2025. <https://developers.googleblog.com/en/generate-images-gemini-2-0-flash-preview>.
- [46] Y. Mehdi, „Reinventing search with a new AI-powered Microsoft Bing and Edge, your copilot for the web,” Microsoft, 2023. Reinventing search with a new AI-powered Microsoft Bing and Edge, your copilot for the web.
- [47] M. Woliński, „Anatomia PLLuM-a,” IPI PAN, 2024. <https://pllum.org.pl/blog/posts/anatomia-plluma>.
- [48] A. Tomaszewska, „Czym karmimy PLLuM-a,” IPI PAN, 2024. <https://pllum.org.pl/blog/posts/czym-karmimy-plluma>.
- [49] A. Tomaszewska, „Pozyskiwanie w PLLuM,” IPI PAN, 2024. <https://pllum.org.pl/blog/posts/pozyskiwanie-w-pllum>.
- [50] E. Rudnicka, „No to PLLuM!,” KSI Politechnika Wrocławska, 2024. <https://pllum.org.pl/blog/posts/no-to-pllum>.
- [51] OpenAI, „DALL·E 3,” OpenAI, 2024. <https://openai.com/index/dall-e-3/>.
- [52] Microsoft, „Kreator Obrazów,” Microsoft, <https://www.bing.com/images/>.
- [53] Suno, „Suno About,” Suno, <https://suno.com/about>.
- [54] OpenAI, „Sora Overview,” OpenAI, 2025. <https://openai.com/sora/>.
- [55] DeepMotion, „Text to 3D Animation,” DeepMotion, <https://deepmotion.com/doc/saymotion>.
- [56] K. Niewęglowski, N. Wilczek, B. Madoń, J. Palmi i M. Wasyluk, „Zastosowania sztucznej inteligencji (AI) w medycynie,” *Medycyna Ogólna i Nauki o Zdrowiu*, 2021.
- [57] A. Jóźwiak i A. Świdorski, „Algorytmy sztucznej inteligencji w logistyce,” *Prace Naukowe Politechniki Warszawskiej. Transport*, 2017.
- [58] M. Torczyńska, „Sztuczna inteligencja i jej społeczno-kulturowe implikacje w codziennym życiu,” *Kultura i Historia*, nr 36, pp. 106-124, 2019.
- [59] T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. Kaplan i e. al., „Language Models are Few-Shot Learners,” 2020.

- [60] J. Z.-Y. He, S. Pandey, M. L. Schrum i A. Dragan, „Context Steering: Controllable Personalization at Inference Time,” 2025.
- [61] S. Banerjee, A. Sahoo, S. Layek, A. Dutta, R. Hazra i A. Mukherjee, „Context Matters: Pushing the Boundaries of Open-Ended Answer Generation with Graph-Structured Knowledge Context,” 2024.
- [62] D. Gambetta, G. Gezici, F. Giannotti, D. Pedreschi, A. Knott i L. Pappalardo, „Characterizing Model Collapse in Large Language Models Using Semantic Networks and Next-Token Probability,” 2025.

Spis wykresów

Wykres 4.1 Struktura płciowa uczestników badania	32
Wykres 4.2 Struktura wiekowa uczestników badania	33
Wykres 5.1 Częstotliwość korzystania z narzędzi AI.....	35
Wykres 5.2 Główne cele korzystania z AI.....	36
Wykres 5.3 Zależność jakości odpowiedzi od formy pytania	36
Wykres 5.4 Ocena wpływu kontekstu na jakość odpowiedzi AI.....	37
Wykres 5.5 Reakcja użytkowników na niezadowolające odpowiedzi AI	37
Wykres 5.6 Wpływ zmiany pytania na odpowiedź AI	37
Wykres 5.7 Ocena użyteczności odpowiedzi udzielanych przez AI	38
Wykres 5.8 Preferencje użytkowników odnośnie pytań.....	38
Wykres 5.9 Potrzeba lepszego uwzględniania kontekstu przez AI	39
Wykres 5.10 Oczekiwane usprawnienia systemów AI.....	39
Wykres 5.11 Sugestie użytkowników na temat interpretacji zapytań przez narzędzia AI ..	39
Wykres 5.12 Zaufanie do odpowiedzi bez zawartego kontekstu.....	40
Wykres 5.13 Interpretacja intencji przy ograniczonych danych.....	40
Wykres 5.14 Obawy w związku z interpretacją kontekstu przez systemy AI	41
Wykres 5.15 Informowanie użytkownika o wpływie kontekstu na generowaną odpowiedź	41
Wykres 5.16 Elementy pytania mające wpływ na jakość odpowiedzi AI	42
Wykres 5.17 Ocena kontekstu w odpowiedziach dotyczących nauki języków obcych	42
Wykres 5.18 Ocena kontekstu w odpowiedziach dotyczących zdrowego odżywiania	43
Wykres 5.19 Ocena kontekstu w odpowiedziach dotyczących sztucznej inteligencji	43
Wykres 5.20 Ocena kontekstu w odpowiedziach dotyczących zmian klimatycznych.....	44
Wykres 5.21 Typ formułowanych pytań kierowanych do systemów AI	44
Wykres 5.22 Ocena szczegółowości kontekstu przy generowaniu obrazów.....	45
Wykres 5.23 Ocena poprawności rozwiązania matematycznego	45
Wykres 5.24 Ocena trafności konspektów maturalnych	46
Wykres 5.25 Ocena jakości odpowiedzi AI na pytanie otwarte	46
Wykres 5.26 Macierz wartości F1 dla różnych modeli AI i zapytań testowych	47
Wykres 5.27 Macierz wartości czułości dla wybranych modeli językowych w odpowiedzi na zapytania testowe	48
Wykres 5.28 Macierz wartości precyzji dla wybranych modeli językowych w odpowiedzi na zapytania testowe	48
Wykres 5.29 Macierz wyników BLEU dla odpowiedzi generowanych przez wybrane modele AI	49
Wykres 5.30 Macierz podobieństwa cosinusowego między pytaniem, a odpowiedziami modeli	50
Wykres 5.31 Macierz wartości Jaccarda w celu porównania zbioru tokenów odpowiedzi	50
Wykres 5.32 Długość odpowiedzi wygenerowanych przez poszczególne modele.....	51
Wykres 5.33 Macierz wyników ROUGE-1 - zgodność unigramów odpowiedzi z pytaniem	52
Wykres 5.34 Macierz wyników ROUGE-2 - pokrycie bigramów względem pytania	52
Wykres 5.35 Macierz wyników ROUGE-L - zgodność najdłuższych wspólnych sekwencji tokenów	53
Wykres 5.36 Liczba unikalnych tokenów w odpowiedziach poszczególnych modeli.....	53
Wykres 5.37 Zależność inercji od liczby klastrów (metoda łokcia).....	54
Wykres 5.38 Rozkład użytkowników na płaszczyźnie Q1 i Q2.....	55
Wykres 5.39 Podział klastrów w przestrzeni głównych składowych	56
Wykres 5.40 Macierz korelacji cech.....	57

Spis rysunków

Rysunek 5.1 Wartości dla współczynnika Silhouette	54
Rysunek 5.2 Wyniki wskaźników Calinski-Harabasz i Davies-Bouldin.....	55
Rysunek 5.3 Graf z węzłami użytkowników	58

Spis załączników

Załącznik 1. Ankieta na temat wpływu kontekstu zapytań i treści zadań wprowadzanych do sztucznej inteligencji na generowane odpowiedzi.

Kwestionariusz badawczy wykorzystany w analizie, zawierający pytania dotyczące oceny jakości wygenerowanych odpowiedzi w zależności od zastosowanego kontekstu i formy zapytania.

Plik dostępny: [[Link do ankiety](#)]

Załącznik 2. Zestaw pytań wprowadzanych do modeli językowych

Plik zawiera szczegółowe informacje dla każdego pytania, takie jak: kategoria, typ zastosowanego kontekstu, długość zapytania oraz zawartość słów kluczowych.

Plik dostępny: [[Link do zestawu pytań](#)]

Załącznik 3. Odpowiedzi wygenerowane przez poszczególne modele

Zestawienie wszystkich odpowiedzi wygenerowanych przez modele językowe w ramach przeprowadzonych eksperymentów, przypisanych do odpowiednich pytań.

Plik dostępny: [[Link do wygenerowanych odpowiedzi](#)]

Załącznik 4. Program porównujący odpowiedzi modeli z wykorzystaniem wybranych metryk jakościowych i ilościowych.

Skrypt opracowany na potrzeby pracy, umożliwiający analizę ilościową i jakościową odpowiedzi generowanych przez różne modele językowe.

Plik dostępny: [[Link do programu](#)]